

Ngapi_tutorial

July 26, 2026

0.1 Ngapi Semantic Chunker Tutorial

0.2 Ye Kyaw Thu, Lab Leader, Language Understanding Lab, Myanmar

0.3 Date: 26 July 2026

Github link: <https://github.com/ye-kyaw-thu/NgaPi>

Reference Youtube Video: <https://www.youtube.com/watch?v=80JC21T2SL4&t=2112s>

0.4 How Semantic Tokenization (Chunking) Works in ngapi.py

The provided script (ngapi.py) implements a semantic text chunking algorithm based on embedding distances. Instead of splitting text strictly by fixed character lengths or punctuation, it looks at how the meaning of text shifts continuously using FastText word embeddings and cosine distance.

Here is the step-by-step breakdown of how the process works:


1. Syllable Breaking & Grouping:
 - If `--apply_syllable_break` is enabled, regular expressions break the raw Myanmar text down into individual syllables.
 - It then groups these pieces into uniform blocks based on `--syllable_group_length` (e.g., groups of 6 syllables) to form base units (sentences/tokens).
2. Context Window Expansion (Combining Sentences):
 - Using the `combine_sentences` function, each text group is merged with its surrounding neighbors (using a buffer size) to create a `combined_sentence`. This ensures that local context is preserved when calculating meaning.
3. Document Embedding Generation:
 - The script loads a FastText binary model (`.bin`) and maps each word to its vector.
 - It calculates the mean embedding vector for each combined sentence group (`embed_documents`).
4. Distance Calculation:
 - It computes the cosine similarity between sequential combined sentence vectors, and transforms it into a distance metric: $\text{Distance} = 1 - \text{Cosine Similarity}$. A higher distance indicates a sharper shift in topic or meaning.
5. Thresholding & Splitting (The Semantic Breakpoints):
 - A cutoff threshold is calculated using a percentile threshold (e.g., `--percentile_threshold 70`, meaning distances in the top 30% are treated as significant topic shifts).

- Points where the distance exceeds this threshold are marked as breakpoints (boundaries where a new semantic chunk begins).

6. Reconstruction & Formatting:

- The text segments between breakpoints are merged back together (stripping internal spaces and joining syllables with `--syllable_group_separator`) to form final semantic chunks.

```
[50]: from IPython.display import Image, display  
  
display(Image(filename='overview.png', width=300))
```



```

[1]: %pwd
[1]: '/home/ye/aif2/word-seg'
[2]: %cd tool
/home/ye/aif2/word-seg/tool
[3]: !mkdir ngapi
[4]: %cd ngapi
/home/ye/aif2/word-seg/tool/ngapi
[5]: !wget https://github.com/ye-kyaw-thu/NgaPi/raw/refs/heads/main/ngapi.py

--2026-07-26 10:40:47-- https://github.com/ye-kyaw-thu/NgaPi/raw/refs/heads/main/ngapi.py
Resolving github.com (github.com)... 20.205.243.166
Connecting to github.com (github.com)|20.205.243.166|:443... connected.
HTTP request sent, awaiting response... 302 Found
Location: https://raw.githubusercontent.com/ye-kyaw-thu/NgaPi/refs/heads/main/ngapi.py [following]
--2026-07-26 10:40:47-- https://raw.githubusercontent.com/ye-kyaw-thu/NgaPi/refs/heads/main/ngapi.py
Resolving raw.githubusercontent.com (raw.githubusercontent.com)...
185.199.109.133, 185.199.111.133, 185.199.110.133, ...
Connecting to raw.githubusercontent.com
(raw.githubusercontent.com)|185.199.109.133|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 10749 (10K) [text/plain]
Saving to: 'ngapi.py'

ngapi.py          100%[=====>]  10.50K  --.-KB/s    in 0s

2026-07-26 10:40:48 (37.0 MB/s) - 'ngapi.py' saved [10749/10749]

```

0.5 Prepare Data

```

[6]: !wget https://github.com/ye-kyaw-thu/NgaPi/raw/refs/heads/main/test/ma_thaung.
      ↪txt

--2026-07-26 10:41:42-- https://github.com/ye-kyaw-thu/NgaPi/raw/refs/heads/main/test/ma_thaung.txt
Resolving github.com (github.com)... 20.205.243.166
Connecting to github.com (github.com)|20.205.243.166|:443... connected.

```

```

HTTP request sent, awaiting response... 302 Found
Location: https://raw.githubusercontent.com/ye-kyaw-
thu/NgaPi/refs/heads/main/test/ma_thaung.txt [following]
--2026-07-26 10:41:42-- https://raw.githubusercontent.com/ye-kyaw-
thu/NgaPi/refs/heads/main/test/ma_thaung.txt
Resolving raw.githubusercontent.com (raw.githubusercontent.com)...
185.199.108.133, 185.199.111.133, 185.199.110.133, ...
Connecting to raw.githubusercontent.com
(raw.githubusercontent.com)|185.199.108.133|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 1670 (1.6K) [text/plain]
Saving to: 'ma_thaung.txt'

ma_thaung.txt      100%[=====>]    1.63K  --.-KB/s    in 0s

2026-07-26 10:41:43 (21.8 MB/s) - 'ma_thaung.txt' saved [1670/1670]

```

```
[7]: !wget https://github.com/ye-kyaw-thu/NgaPi/raw/refs/heads/main/test/ma_thein.txt
```

```

--2026-07-26 10:42:03-- https://github.com/ye-kyaw-
thu/NgaPi/raw/refs/heads/main/test/ma_thein.txt
Resolving github.com (github.com)... 20.205.243.166
Connecting to github.com (github.com)|20.205.243.166|:443... connected.
HTTP request sent, awaiting response... 302 Found
Location: https://raw.githubusercontent.com/ye-kyaw-
thu/NgaPi/refs/heads/main/test/ma_thein.txt [following]
--2026-07-26 10:42:03-- https://raw.githubusercontent.com/ye-kyaw-
thu/NgaPi/refs/heads/main/test/ma_thein.txt
Resolving raw.githubusercontent.com (raw.githubusercontent.com)...
185.199.111.133, 185.199.108.133, 185.199.110.133, ...
Connecting to raw.githubusercontent.com
(raw.githubusercontent.com)|185.199.111.133|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 2836 (2.8K) [text/plain]
Saving to: 'ma_thein.txt'

ma_thein.txt      100%[=====>]    2.77K  --.-KB/s    in 0s

2026-07-26 10:42:04 (33.6 MB/s) - 'ma_thein.txt' saved [2836/2836]

```

0.6 Prepare Shell Scripts

```
[28]: !wget https://github.com/ye-kyaw-thu/NgaPi/raw/refs/heads/main/test/exp1.sh
```

```

--2026-07-26 14:00:36-- https://github.com/ye-kyaw-
thu/NgaPi/raw/refs/heads/main/test/exp1.sh

```

```

Resolving github.com (github.com)... 20.205.243.166
Connecting to github.com (github.com)|20.205.243.166|:443... connected.
HTTP request sent, awaiting response... 302 Found
Location: https://raw.githubusercontent.com/ye-kyaw-
thu/NgaPi/refs/heads/main/test/exp1.sh [following]
--2026-07-26 14:00:36-- https://raw.githubusercontent.com/ye-kyaw-
thu/NgaPi/refs/heads/main/test/exp1.sh
Resolving raw.githubusercontent.com (raw.githubusercontent.com)...
185.199.110.133, 185.199.111.133, 185.199.109.133, ...
Connecting to raw.githubusercontent.com
(raw.githubusercontent.com)|185.199.110.133|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 1729 (1.7K) [text/plain]
Saving to: 'exp1.sh.1'

```

```
exp1.sh.1          100%[=====>]    1.69K  --.-KB/s    in 0s
```

```
2026-07-26 14:00:37 (25.2 MB/s) - 'exp1.sh.1' saved [1729/1729]
```

```
[29]: from IPython.display import Markdown
```

```

# Read the shell script file
with open("exp1.sh", "r") as file:
    script_content = file.read()

# Print with syntax highlighting using Markdown
display(Markdown(f"```bash\n{script_content}\n```"))

```

```
#!/bin/bash
```

```

## Test commands run by Ye, LU Lab., Myanmar
## Test input filename is ma_thein.txt.
## Date: 25 Dec 2024

```

```
mkdir exp1;
```

```
## Test-1
```

```

time python ./ngapi.py --model ./myanmar_fasttext.model --input ./ma_thein.txt \
--graph_filename ./exp1/tst1.distances-eg1 --chunk_filename ./exp1/ma_thein.chunk1.txt --appl
--syllable_group_separator "_" --chunk_separator "|"

```

```
## Test-2
```

```

time python ./ngapi.py --model ./myanmar_fasttext.model --input ./ma_thein.txt \
--graph_filename ./exp1/tst1.distances-eg2 --chunk_filename ./exp1/ma_thein.chunk2.txt --perce
--apply_syllable_break --chunks_per_line 5 \
--syllable_group_separator "_" --chunk_separator "|"

```

Test-3

```
time python ./ngapi.py --model ./myanmar_fasttext.model --input ./ma_thein.txt \  
--graph_filename ./exp1/tst1.distances-eg3 --chunk_filename ./exp1/ma_thein.chunk3.txt --perce  
--y_upper_bound 0.5 --apply_syllable_break --chunks_per_line 5 \  
--syllable_group_separator "_" --chunk_separator "|"
```

Test-4

```
time python ./ngapi.py --model ./myanmar_fasttext.model --input ./ma_thein.txt \  
--graph_filename ./exp1/tst1.distances-eg4 --chunk_filename ./exp1/ma_thein.chunk4.txt --perce  
--y_upper_bound 0.5 --syllable_group_length 5 --apply_syllable_break \  
--chunks_per_line 10 --syllable_group_separator "_" --chunk_separator "|"
```

Test-5

```
time python ./ngapi.py --model ./myanmar_fasttext.model --input ./ma_thein.txt \  
--graph_filename ./exp1/tst1.distances-eg5 --chunk_filename ./exp1/ma_thein.chunk5.txt --perce  
--y_upper_bound 0.1 --syllable_group_length 1 --apply_syllable_break \  
--chunks_per_line 10 --syllable_group_separator "_" --chunk_separator "|"
```

[31]: `!wget https://github.com/ye-kyaw-thu/NgaPi/raw/refs/heads/main/test/exp2.sh`

```
--2026-07-26 14:01:07-- https://github.com/ye-kyaw-  
thu/NgaPi/raw/refs/heads/main/test/exp2.sh  
Resolving github.com (github.com)... 20.205.243.166  
Connecting to github.com (github.com)|20.205.243.166|:443... connected.  
HTTP request sent, awaiting response... 302 Found  
Location: https://raw.githubusercontent.com/ye-kyaw-  
thu/NgaPi/refs/heads/main/test/exp2.sh [following]  
--2026-07-26 14:01:07-- https://raw.githubusercontent.com/ye-kyaw-  
thu/NgaPi/refs/heads/main/test/exp2.sh  
Resolving raw.githubusercontent.com (raw.githubusercontent.com)...  
185.199.111.133, 185.199.110.133, 185.199.108.133, ...  
Connecting to raw.githubusercontent.com  
(raw.githubusercontent.com)|185.199.111.133|:443... connected.  
HTTP request sent, awaiting response... 200 OK  
Length: 1740 (1.7K) [text/plain]  
Saving to: 'exp2.sh.1'  
  
exp2.sh.1          100%[=====>]    1.70K  --.-KB/s    in 0s  
  
2026-07-26 14:01:08 (24.6 MB/s) - 'exp2.sh.1' saved [1740/1740]
```

[32]: `from IPython.display import Markdown`

```
# Read the shell script file  
with open("exp2.sh", "r") as file:  
    script_content = file.read()
```

```
# Print with syntax highlighting using Markdown
display(Markdown(f"```bash\n{script_content}\n```"))
```

```
#!/bin/bash
```

```
## Test commands run by Ye, LU Lab., Myanmar
## Test input filename is ma_thaung.txt.
## Date: 25 Dec 2024
```

```
mkdir exp2;
```

```
## Test-1
```

```
time python ./ngapi.py --model ./model/myfasttext_v1.bin --input ./ma_thaung.txt \
--graph_filename ./exp2/tst2.distances-eg1 --chunk_filename ./exp2/ma_thaung.chunk1.txt \
--apply_syllable_break --chunks_per_line 3 \
--syllable_group_separator "_" --chunk_separator "|"
```

```
## Test-2
```

```
time python ./ngapi.py --model ./model/myfasttext_v1.bin --input ./ma_thaung.txt \
--graph_filename ./exp2/tst2.distances-eg2 --chunk_filename ./exp2/ma_thaung.chunk2.txt \
--percentile_threshold 50 --apply_syllable_break \
--syllable_group_separator "_" --chunk_separator "|"
```

```
## Test-3
```

```
time python ./ngapi.py --model ./model/myfasttext_v1.bin --input ./ma_thaung.txt \
--graph_filename ./exp2/tst2.distances-eg3 --chunk_filename ./exp2/ma_thaung.chunk3.txt \
--percentile_threshold 60 --y_upper_bound 0.6 --apply_syllable_break --chunks_per_line 2 \
--syllable_group_separator "_" --chunk_separator "|"
```

```
## Test-4
```

```
time python ./ngapi.py --model ./model/myfasttext_v1.bin --input ./ma_thaung.txt \
--graph_filename ./exp2/tst2.distances-eg4 --chunk_filename ./exp2/ma_thaung.chunk4.txt \
--percentile_threshold 70 --y_upper_bound 0.6 --syllable_group_length 5 --apply_syllable_break
--chunks_per_line 10 --syllable_group_separator "_" --chunk_separator "|"
```

```
## Test-5
```

```
time python ./ngapi.py --model ./model/myfasttext_v1.bin --input ./ma_thaung.txt \
--graph_filename ./exp2/tst2.distances-eg5 --chunk_filename ./exp2/ma_thaung.chunk5.txt \
--percentile_threshold 30 --y_upper_bound 0.5 --syllable_group_length 1 --apply_syllable_break
--chunks_per_line 10 --syllable_group_separator "_" --chunk_separator "|"
```

0.7 Prepare FastText Model File

[26]: !wget https://huggingface.co/ye-nlp/mySyllableFastText-Version1/resolve/main/
↪myfasttext_v1.bin

```
--2026-07-26 10:54:17-- https://huggingface.co/ye-nlp/mySyllableFastText-
Version1/resolve/main/myfasttext_v1.bin
Resolving huggingface.co (huggingface.co)... 18.65.14.87, 18.65.14.85,
```


exp1:

```
[33]: !mv myfasttext_v1.bin ./model/
```

0.8 FastText Python Library Installation

```
[24]: !pip install fasttext --break-system-packages
```

```
Defaulting to user installation because normal site-packages is not writeable
Collecting fasttext
  Downloading fasttext-0.9.3.tar.gz (73 kB)
  Installing build dependencies ... done
  Getting requirements to build wheel ... done
  Preparing metadata (pyproject.toml) ... done
Collecting pybind11>=2.2 (from fasttext)
  Using cached pybind11-3.0.4-py3-none-any.whl.metadata (10 kB)
Requirement already satisfied: setuptools>=0.7.0 in /usr/lib/python3/dist-packages (from fasttext) (68.1.2)
Requirement already satisfied: numpy in /home/ye/.local/lib/python3.12/site-packages (from fasttext) (2.1.3)
Using cached pybind11-3.0.4-py3-none-any.whl (314 kB)
Building wheels for collected packages: fasttext
  Building wheel for fasttext (pyproject.toml) ... done
  Created wheel for fasttext:
    filename=fasttext-0.9.3-cp312-cp312-linux_x86_64.whl size=4553716
    sha256=06b35d16c49f4ec68f2d3bb465352abe1b37fc2baf9fa3f9c1c8bc60b0ae04ba
  Stored in directory: /mnt/disk1/ye/.cache/pip/wheels/20/27/95/a7baf1b435f1cbde017cabdf1e9688526d2b0e929255a359c6
Successfully built fasttext
Installing collected packages: pybind11, fasttext
    2/2 [fasttext]
Successfully installed fasttext-0.9.3 pybind11-3.0.4
```

0.9 Run Experiment-1

```
[34]: %pwd
```

```
[34]: '/home/ye/aif2/word-seg/tool/ngapi'
```

```
[15]: !time ./exp1.sh
```

```
/bin/bash: line 1: ./exp1.sh: Permission denied
```

```
real    0m0.002s
user    0m0.001s
sys     0m0.000s
```

```
[16]: !ls *.sh -lh
```

```
-rw-rw-r-- 1 ye ye 1.7K Jul 26 10:42 exp1.sh
-rw-rw-r-- 1 ye ye 1.7K Jul 26 10:43 exp2.sh
```

```
[17]: !chmod +x *.sh
```

```
[18]: !ls *.sh -lh
```

```
-rwxrwxr-x 1 ye ye 1.7K Jul 26 10:42 exp1.sh
-rwxrwxr-x 1 ye ye 1.7K Jul 26 10:43 exp2.sh
```

```
[36]: !time ./exp1.sh
```

```
mkdir: cannot create directory 'exp1': File exists
No. of chunks: 16
Chunk line #1
ရွှေတိဂုံဘုရားအ
Chunk line #2
နောက်ဘက်စောင်းတန်းမှာမ_ သိန်းဆိုတဲ့ပန်းသည်တ_ ယောက်ရှိတယ်။ပန်းသည်
Chunk line #3
မသိန်းပုံကိုသိပ္ပံမောင်_ ဝရေးဖွဲ့ခဲ့ပုံက
Chunk line #4
...။
Chunk line #5
" မသိန်းသည်ပန်းသည်
Chunk line #6
တို့အနက်အတော်ပင်_ ယဉ်စစ်ရှိ၏။_ အပြောလည်းကောင်း၊သ_ ဘောလည်းကောင်း၊အပြု_
အပြင်ကလည်းကောင်း
_ သူ့မှာအကောင်းချည်းစု_ နေလေတော့သည်။သို့_ ဖြစ်သောကြောင့်တက္ကသိုလ်
Chunk line #7
ကျောင်းသားတွေသူ့ဆိုင်မှာ_ ချည်းပန်းဝယ်ကြလေသည်_ ။" _ အဲဒီခေတ်ကတက္ကသိုလ်
Chunk line #8
ကျောင်းသားတွေဟာစနေ_ တနင်္ဂနွေနေ့တွေ
Chunk line #9
မှာအုပ်စုလိုက်ဘုရား_ တက်ပြီးမသိန်းဆိုင်က_ ပန်းတွေဝယ်၊မသိန်း
Chunk line #10
ဆိုင်ရှေ့ကနံ့မှာထိုင်_ ပြီးစကားတွေဖောင်ဖွဲ့_ ကြပါသတဲ့။_ တချို့ရက်တွေဆိုရှေ့_ ကအဖွဲ့ဖ
ောင်ဖွဲ့နေ_ တုန်းနောက်တဖွဲ့ရောက်လာ_ လို့မထချင်ထချင်_ နဲ့နေရာဖယ်ပေးရ_ ဆိုပဲ။ဒီထဲမောင်
_ သိန်းခိုင်ဆိုတဲ့ကျောင်းသား
Chunk line #11
ကတော့တကိုယ်တော်။_ သူကမသိန်းဆိုင်သိမ်း_ ချိန်အထိနေပြီးဆိုင်_ သိမ်းပြီးရင်အတူပြန်_ တဲ့
ထိမသိန်းနဲ့ရင်း_ နီးတယ်။ဒီလိုနဲ့
Chunk line #12
ကျောင်းသားဟောင်းတွေကကျောင်း
```

Chunk line #13

ပြီးသွားလို့နေရပ်အ

Chunk line #14

သီသီးဆီဘဝခ

Chunk line #15

ရိုးချီတက်ကြ။_ နောက်ကျောင်းသားအသစ်တွေ_ ရောက်လာပြီးမသိန်းဆိုင်

Chunk line #16

မှာပန်းဝယ်ကြ။စ_ ကားတွေဖောင်ဖွဲ့ကြနဲ့_ ။ဆယ်စုနှစ်နှစ်ခု_ လောက်ရှိတော့မသိန်းဆိုင်_ နား
မှာမသောင်းပန်းဆိုင်_ ပေါ်လာ။

Chunks saved to ./exp1/ma_thein.chunk1.txt

real 0m1.642s

user 0m6.147s

sys 0m0.410s

No. of chunks: 31

Chunk line #1

ရွှေတိဂုံဘုရားအ | နောက်ဘက်စောင်းတန်းမှာမ | သိန်းဆိုတဲ့ပန်းသည်တ_ ယောက်ရှိတယ်။ပန်းသည် | မ
သိန်းပုံကိုသိပ္ပံမောင် | ဝရေးဖွဲ့ခဲ့ပုံက

Chunk line #2

... ။ | " မသိန်းသည်ပန်းသည် | တို့အနက်အတော်ပင်_ ယဉ်စစ်ရှိ၏။_ အပြောလည်းကောင်း၊သ_ _ပ

↪ဘောလည်းကောင်း

၊အပြု_ အပြင်ကလည်းကောင်း။ သူ့မှာအကောင်းချည်းစု_ နေလေတော့သည်။သို့_ ဖြစ်သောကြောင့်တက္က
သိုလ် | ကျောင်းသားတွေသူ့ဆိုင်မှာ_ ချည်းပန်းဝယ်ကြလေသည်

Chunk line #3

။" | အဲဒီခေတ်ကတက္ကသိုလ် | ကျောင်းသားတွေဟာစနေ | တနင်္ဂနွေနေ့တွေ | မှာအုပ်စုလိုက်ဘုရား

Chunk line #4

တက်ပြီးမသိန်းဆိုင်က | ပန်းတွေဝယ်၊မသိန်း | ဆိုင်ရှေ့ကခုမှာထိုင်_ ပြီးစကားတွေဖောင်ဖွဲ့
_ ကြပါသတဲ့။ | တချို့ရက်တွေဆိုရှေ့_ ကအဖွဲ့ဖောင်ဖွဲ့နေ_ တုန်းနောက်တဖွဲ့ရောက်လာ | လို့မထချ
င်ထချင်

Chunk line #5

နဲ့နေရာဖယ်ပေးရ_ ဆိုပဲ။ဒီထဲမောင် | သိန်းခိုင်ဆိုတဲ့ကျောင်းသား | ကတော့တကိုယ်တော်။_ သူကမသ
ိန်းဆိုင်သိမ်း_ ချိန်အထိနေပြီးဆိုင်_ သိမ်းပြီးရင်အတူပြန်_ တဲ့ထိမသိန်းနဲ့ရင်း_ နှီးတယ
်။ဒီလိုနဲ့ | ကျောင်းသားဟောင်းတွေကကျောင်း | ပြီးသွားလို့နေရပ်အ

Chunk line #6

သီသီးဆီဘဝခ | ရိုးချီတက်ကြ။ | နောက်ကျောင်းသားအသစ်တွေ_ ရောက်လာပြီးမသိန်းဆိုင် | မှာပန်းဝယ်
ကြ။စ | ကားတွေဖောင်ဖွဲ့ကြနဲ့

Chunk line #7

။ဆယ်စုနှစ်နှစ်ခု_ လောက်ရှိတော့မသိန်းဆိုင်_ နားမှာမသောင်းပန်းဆိုင်_ ပေါ်လာ။

Chunks saved to ./exp1/ma_thein.chunk2.txt

real 0m1.489s

user 0m6.135s

sys 0m0.397s

No. of chunks: 36

Chunk line #1

ရွှေတိဂုံဘုရားအ | နောက်ဘက်စောင်းတန်းမှာမ | သိန်းဆိုတဲ့ပန်းသည်တ_ယောက်ရှိတယ်။ပန်းသည် | မ
သိန်းပုံကိုသိပ္ပံမောင် | ဝရေးဖွဲ့ခဲ့ပုံက

Chunk line #2

...။" မသိန်းသည်ပန်းသည် | တို့အနက်အတော်ပင်_ယဉ်စစ်ရှိ၏။_အပြောလည်းကောင်း၊သ_

ဘောလည်းကောင်း

၊အပြု_အပြင်ကလည်းကောင်း၊ သူ့မှာအကောင်းချည်းစု_နေလေတော့သည်။သို့_ဖြစ်သောကြောင့်တက္က
သိုလ် | ကျောင်းသားတွေသူ့ဆိုင်မှာ

Chunk line #3

ချည်းပန်းဝယ်ကြလေသည်။" | အဲ့ဒီခေတ်ကတက္ကသိုလ် | ကျောင်းသားတွေဟာစနေ | တနင်္ဂနွေနေ့တွေ

Chunk line #4

မှာအုပ်စုလိုက်ဘုရား | တက်ပြီးမသိန်းဆိုင်က | ပန်းတွေဝယ်၊မသိန်း | ဆိုင်ရှေ့ကနဲ့မှာထိုင် |
ပြီးစကားတွေဖောင်ဖွဲ့_ကြပါသတဲ့။

Chunk line #5

တချို့ရက်တွေဆိုရှေ့ | ကအဖွဲ့ဖောင်ဖွဲ့နေ_တုန်းနောက်တဖွဲ့ရောက်လာ | လို့မထချင်ထချင် | နဲ့
နေရာဖယ်ပေးရ | ဆိုပဲ။ဒီထဲမောင်

Chunk line #6

သိန်းခိုင်ဆိုတဲ့ကျောင်းသား | ကတော့တကိုယ်တော်။_သူကမသိန်းဆိုင်သိမ်း_ချိန်အထိနေပြီးဆိ
ုင်_သိမ်းပြီးရင်အတူပြန်_တဲ့ထိမသိန်းနဲ့ရင်း | နီးတယ်။ဒီလိုနဲ့ | ကျောင်းသားဟောင်းတွေက
ကျောင်း | ပြီးသွားလို့နေရပ်အ

Chunk line #7

သီသီးဆီဘဝခ | ရိုးချီတက်ကြ။ | နောက်ကျောင်းသားအသစ်တွေ_ရောက်လာပြီးမသိန်းဆိုင် | မှာပန်းဝယ်
ကြစ | ကားတွေဖောင်ဖွဲ့ကြနဲ့

Chunk line #8

။ဆယ်စုနှစ်နှစ်ခု_လောက်ရှိတော့မသိန်းဆိုင်_နားမှာမသောင်းပန်းဆိုင်_ပေါ်လာ။

Chunks saved to ./exp1/ma_thein.chunk3.txt

real 0m1.510s

user 0m5.953s

sys 0m0.395s

No. of chunks: 19

Chunk line #1

ရွှေတိဂုံဘုရား | အနောက်ဘက်စောင်းတန်း_မှာမသိန်းဆိုတဲ့_ပန်းသည်တယောက်ရှိ_တယ်။ပန်းသည်မ
| သိန်းပုံကိုသိပ္ပံမောင်_ဝရေးဖွဲ့ခဲ့ပုံ_က...။" မသိန်းသည်ပန်း_သည်တို့အနက်အ_တော်ပင်ယဉ်
စစ်_ရှိ၏။အပြော_လည်းကောင်း၊သဘော_လည်းကောင်း၊အပြု_အပြင်ကလည်းကောင်း_၊သူ့မှာအကောင်း |

ချ

ည်းစုနေလေတော့ | သည်။သို့ဖြစ်သော | ကြောင့်တက္ကသိုလ်ကျောင်း | သားတွေသူ့ဆိုင်မှာ_ချည်းပန်
းဝယ်ကြလေ_သည်။"- အဲ့ဒီခေတ်ကတက္က_သိုလ်ကျောင်းသားတွေဟာ | စနေ၊တနင်္ဂ_နွေနေ့တွေမှာအုပ်_စ
ုလိုက်ဘုရားတက် | ပြီးမသိန်းဆိုင်က_ပန်းတွေဝယ်၊မ_သိန်းဆိုင်ရှေ့ကနဲ့_မှာထိုင်ပြီးစကား
_တွေဖောင်ဖွဲ့ကြပါ_သတဲ့။_တချို့ရက်တွေဆို_ရှေ့ကအဖွဲ့ဖောင်_ဖွဲ့နေတုန်းနောက်တ_ဖွဲ့ရေ
ာက်လာလို့မ | ထချင်ထချင်နဲ့

Chunk line #2

နေရာဖယ်ပေးရ၊ ဆိုပဲ။ဒီထဲ_မောင်သိန်းခိုင်ဆိုတဲ့_ကျောင်းသားကတော့တ_ကိုယ်တော်။ သူကမသိန
်းဆိုင်_သိမ်းချိန်အထိနေ_ပြီးဆိုင်သိမ်းပြီးရင်_အတူပြန်တဲ့ထိ_မသိန်းနဲ့ရင်းနှီး_တယ်
။ဒီလိုနဲ့_ကျောင်းသားဟောင်းတွေက_ကျောင်းပြီးသွားလို့နေ၊ ရပ်အသီးသီးဆီ_ဘဝခရီးချီ၊ တက်ကြ
။ နောက်ကျောင်းသားအသစ်၊ တွေရောက်လာပြီးမ၊ သိန်းဆိုင်မှာပန်းဝယ်၊ ကြ၊စကားတွေ_ဖောင်ဖွဲ့က
ြနဲ့။_ဆယ်စုနှစ်နှစ်ခု_လောက်ရှိတော့မသိန်း_ဆိုင်နားမှာမသောင်း_ပန်းဆိုင်ပေါ်လာ။

Chunks saved to ./exp1/ma_thein.chunk4.txt

real 0m1.502s

user 0m5.988s

sys 0m0.402s

No. of chunks: 91

Chunk line #1

ရွှေ_တိ_ဂုံ_ဘု_ရား_အ_နောက်_ဘက်_စောင်း_တန်း_မှာ_မ_သိန်း၊ ဆို_တဲ့_ပန်း၊ သည်_တ၊
ယောက်၊

ရှိ၊ တယ်၊ ။၊ ပန်း၊ သည်၊ မ_သိန်း

Chunk line #2

ပုံ၊ ကို၊ သိပ္ပံ၊ မောင်၊ ဝ၊ ရေး၊ ဖွဲ့၊ ခဲ့၊ ပုံ၊ က

Chunk line #3

...၊ ။၊ "၊ မ၊ သိန်း၊ သည်_ပန်း_သည်_တို့_အ_နက်_အ_တော်၊ ပင်_ယဉ်_စ_စ_ရှိ_၏၊ ။_အ_ပြော_၊
လည်း_ကော

င်း_၊_သ_ဘော_လည်း_ကောင်း၊ ။_အ_ပြု_အ_ပြင်_က_လည်း_ကောင်း_၊_သူ_မှာ_အ_ကောင်း_၊
ချည်း_စု

_နေ_လေ_တော့၊ သည်_။_သို့_ဖြစ်_သော

Chunk line #4

ကြော_ငုံ_တက္က_သိုလ်_ကျောင်း_သား_တွေ_သူ_ဆိုင်_မှာ_ချည်း၊ ပန်း_ဝယ်၊ ကြ_လေ_သည်_။_အဲ
ဒီ_ခေတ်_က_တက္က_သိုလ်_ကျောင်း_သား_တွေ_ဟာ၊ စ၊ နေ၊ ။_တ_နဂီ_နွေ_နွေ၊ တွေ_မှာ_၊
အုပ်၊ စု

_လိုက်_ဘု_ရား၊ တက်_ပြီး_မ_သိန်း

Chunk line #5

ဆိုင်၊ က၊ ပန်း၊ တွေ၊ ဝယ်၊ ။၊ မ_သိန်း_ဆိုင်_ရှေ့_က၊ ခုံ_မှာ_ထိုင်_ပြီး_စ၊ ကား၊ တွေ

Chunk line #6

ဖောင်၊ ဖွဲ့_ကြ_ပါ_သ၊ တဲ့_။၊ တ၊ ချို့၊ ရက်၊ တွေ_ဆို_ရှေ့_က_အ၊ ဖွဲ့၊ ဖောင်၊ ဖွဲ့_နေ_တုန်း

Chunk line #7

နောက်_တ_ဖွဲ့_ရောက်_လာ_လို့_မ၊ ထ၊ ချင်_ထ_ချင်_နဲ့_နေ_ရာ_ဖယ်_ပေး_ရ_ဆို_ပဲ_။_ဒီ_၊
ထဲ_မေ

ောင်_သိန်း_ခိုင်၊ ဆို_တဲ့_ကျောင်း_သား_က_တော့_တ၊ ကိုယ်_တော်_။_သူ_က_မ၊ သိန်း၊ ဆိုင်_သိမ
်း၊ ချိန်_အ_ထိ_နေ_ပြီး_ဆိုင်_သိမ်း_ပြီး_ရင်_အ_တူ၊ ပြန်_တဲ့_ထိ_မ၊ သိန်း_နဲ့_ရင်း_နှီး
း

Chunk line #8

တယ်_။_ဒီ_လို_နဲ့_ကျောင်း_သား_ဟောင်း_တွေ_က_ကျောင်း_ပြီး_သွား_လို့_နေ_ရပ်_အ_သီး_သီး
_ဆီ_ဘ_ဝ_ခ_ရီး၊ ချီ_တက်_ကြ၊ ။_နောက်_ကျောင်း_သား_အ_သစ်_တွေ_ရောက်_လာ၊ ပြီး_မ_၊

သိန်း၊ ဆို

င်_မှာ၊ ပန်း၊ ဝယ်၊ ကြ_၊_စ၊ ကား၊ တွေ

Chunk line #9

ဖောင် | ဖွဲ့ | ကြံ | နဲ့ | ။ | ဆယ်_စု_နှစ်_နှစ်_ခု_လောက်_ရှိ_တော့_မ_သိန်း_ဆိုင်_နား | မှာ | မ | သ
ောင်း | ပန်း :

Chunk line #10

ဆိုင်_ပေါ်_လာ_။

Chunks saved to ./exp1/ma_thein.chunk5.txt

```
real    0m1.503s
user    0m6.185s
sys     0m0.382s
```

```
real    0m7.654s
user    0m30.408s
sys     0m1.994s
```

0.10 Check exp1 Folder

```
[45]: !tree ./exp1
```


```
./exp1
  ma_thein.chunk1.txt
  ma_thein.chunk2.txt
  ma_thein.chunk3.txt
  ma_thein.chunk4.txt
  ma_thein.chunk5.txt
  tst1.distances-eg1.pdf
  tst1.distances-eg1.png
  tst1.distances-eg2.pdf
  tst1.distances-eg2.png
  tst1.distances-eg3.pdf
  tst1.distances-eg3.png
  tst1.distances-eg4.pdf
  tst1.distances-eg4.png
  tst1.distances-eg5.pdf
  tst1.distances-eg5.png
```

1 directory, 15 files

```
[37]: from IPython.display import Image

      # Display the PNG image
      Image(filename='./exp1/tst1.distances-eg1.png')
```


```
[37]:
```



```
[42]: from IPython.display import Image

# Display the PNG image
Image(filename='./exp1/tst1.distances-eg2.png')
```


[42]:



```
[43]: from IPython.display import Image

      # Display the PNG image
      Image(filename='./exp1/tst1.distances-eg3.png')
```

[43]:



0.11 Run Experiment-2

```
[38]: %pwd
```

```
[38]: '/home/ye/aif2/word-seg/tool/ngapi'
```

```
[39]: !./exp2.sh
```

No. of chunks: 9

Chunk line #1

ပန်းသည်မသောင်းကအ_ သက်ကဗန္ဓု၊ ယဉ်စနဲ့နုပျို၊ မူခြင်းမှာမသိန်းထက်_ အပုံကြီးသာသပေါ့
။ ဒီတော့တက္ကသိုလ်ကျောင်း သားတွေကပန်းသည်မ_ သောင်းဆိုင်မှာပြောင်းပြီးပန်း_ ဝယ်ကြ၊ စကာ
းတွေ_ ဖောင်ဖွဲ့ကြတာပေါ့။ မသိန်းပန်းဆိုင်အရင်_ လိုမရောင်းရတော့ဘဲ_ ခြောက်ကပ်လာတာပေါ့။
_ ဒီလိုနဲ့တနေ့သူ့_ ပန်းဆိုင်နားကိုလင်မ_ ယားနှစ်ယောက်ကလေးလေး၊ လက်ဆွဲပြီးရောက်လာ။ အမျိုး
ုးသားဖြစ်သူက_ တပ်ထားတဲ့မျက်မှန်ချွတ်_ လိုက်ပြီးကျနော့်မှတ်မိ

Chunk line #2

လားမေး။ မောင်သိန်းခိုင်_ ဖြစ်နေ။ ပန်းသည်မ၊ သိန်းနဲ့ယောက်ျားဖြစ်သူ_ ကိုသိန်းခိုင်တို့စ
ကား_ တွေ့တရင်းတနှီးဖောင်၊ ဖွဲ့နေကြတာကြည့်

Chunk line #3

ပြီးဇနီးဖြစ်သူက၊ အံ့တွေ့သြ။ သိပ္ပံမောင်ဝကဒီမှာ၊ တင်ပန်းသည်စာမူကို_ ရပ်ခဲ့တယ်။

Chunks saved to ./exp2/ma_thaung.chunk1.txt

real 0m1.493s

user 0m6.085s

sys 0m0.424s

No. of chunks: 15

Chunk line #1

ပန်းသည်မသောင်းကအ_သက်ကၢၤန့ၣ်၊

Chunk line #2

ယဉ်စစနဲန့ၣ်ပျို

Chunk line #3

မူခြင်းမှာမသိန်းထက်

Chunk line #4

အပုံကြီးသာသပေါ့

Chunk line #5

။ဒီတော့တက္ကသိုလ်ကျောင်း_သားတွေကပန်းသည်မ_သောင်းဆိုင်မှာပြောင်းပြီးပန်း_ဝယ်ကြ၊စကား
တွေ_ဖောင်ဖွဲ့ကြတာပေါ့။_မသိန်းပန်းဆိုင်အရင်_လိုမရောင်းရတော့ဘဲ_ခြောက်ကပ်လာတာပေါ့။_
ဒီလိုနဲ့တနေ့သူ့_ပန်းဆိုင်နားကိုလင်မ_ယားနှစ်ယောက်ကလေးလေး

Chunk line #6

လက်ဆွဲပြီးရောက်လာ။_အမျိုးသားဖြစ်သူက_တပ်ထားတဲ့မျက်မှန်ချွတ်_လိုက်ပြီးကျနော့်မှတ်မ
ိ

Chunk line #7

လားမေး။မောင်သိန်းခိုင်_ဖြစ်နေ။ပန်းသည်မ

Chunk line #8

သိန်းနဲ့ယောက်ျားဖြစ်သူ

Chunk line #9

ကိုသိန်းခိုင်တို့စကား

Chunk line #10

တွေတရင်းတနှီးဖောင်

Chunk line #11

ဖွဲ့နေကြတာကြည့်

Chunk line #12

ပြီးဇနီးဖြစ်သူက

Chunk line #13

အံ့တွေ့သြ။

Chunk line #14

သိပ္ပံမောင်ဝကဒီမှာ

Chunk line #15

တင်ပန်းသည်စာမူကို_ရပ်ခဲ့တယ်။

Chunks saved to ./exp2/ma_thaung.chunk2.txt

real 0m1.495s

user 0m6.023s

sys 0m0.386s

No. of chunks: 12

Chunk line #1

ပန်းသည်မသောင်းကအ_သက်က၁၆နှစ်၊_ယဉ်စနဲ့နုပျို၊_မူခြင်းမှာမသိန်းထက်_အပုံကြီးသာသပေါ့
_။ဒီတော့တက္ကသိုလ်ကျောင်း_သားတွေကပန်းသည်မ_သောင်းဆိုင်မှာပြောင်းပြီးပန်း_ဝယ်ကြ၊စကာ
းတွေ_ဖောင်ဖွဲ့ကြတာပေါ့။_မသိန်းပန်းဆိုင်အရင်_လိုမရောင်းရတော့ဘဲ_ခြောက်ကပ်လာတာပေါ့။
_ဒီလိုနဲ့တနေ့သူ့_ပန်းဆိုင်နားကိုလင်မ_ယားနှစ်ယောက်ကလေးလေး

Chunk line #2

လက်ဆွဲပြီးရောက်လာ။_အမျိုးသားဖြစ်သူက_တပ်ထားတဲ့မျက်မှန်ချွတ်_လိုက်ပြီးကျနော့်မှတ်မ
ိ၊_လားမေး။မောင်သိန်းခိုင်_ဖြစ်နေ။ပန်းသည်မ

Chunk line #3

သိန်းနဲ့ယောက်ျားဖြစ်သူ၊_ကိုသိန်းခိုင်တို့စကား

Chunk line #4

တွေတရင်းတနှီးဖောင်၊_ဖွဲ့နေကြတာကြည့်

Chunk line #5

ပြီးဇနီးဖြစ်သူက၊_အံ့တွေ့သြ။

Chunk line #6

သိပ္ပံမောင်ဝကဒီမှာ၊_တင်ပန်းသည်စာမူကို_ရပ်ခဲ့တယ်။

Chunks saved to ./exp2/ma_thaung.chunk3.txt

real 0m1.467s

user 0m6.130s

sys 0m0.398s

No. of chunks: 11

Chunk line #1

ပန်းသည်မသောင်းက_အသက်က၁၆_နှစ်၊ယဉ်စစ_နဲ့နုပျိုမူခြင်း၊_မှာမသိန်းထက်အ_ပုံကြီးသာသပေါ့
့_။ဒီတော့တက္ကသိုလ်_ကျောင်းသားတွေကပန်း_သည်မသောင်းဆိုင်မှာ_ပြောင်းပြီးပန်းဝယ်ကြ_စ
ကားတွေဖောင်_ဖွဲ့ကြတာပေါ့။_မသိန်းပန်းဆိုင်အ_ရင်လိုမရောင်းရ_တော့ဘဲခြောက်ကပ်လာ_တာပေ
့။ဒီလို_နဲ့တနေ့သူ့ပန်း_ဆိုင်နားကိုလင်မ_ယားနှစ်ယောက်ကလေး_လေးလက်ဆွဲပြီးရောက်_လာ။အ
မျိုးသား_ဖြစ်သူကတပ်ထား_တဲ့မျက်မှန်ချွတ်လိုက်_ပြီးကျနော့်မှတ်မိ၊_လားမေး။မောင်သိန်း
_ခိုင်ဖြစ်နေ။ပန်း_သည်မသိန်းနဲ့ယောက်ျားဖြစ်သူကိုသိန်း၊_ခိုင်တို့စကားတွေ၊_တရင်းတနှီး
းဖောင်၊_ဖွဲ့နေကြတာကြ၊_ညှိပြီးဇနီးဖြစ်၊_သူကအံ့တွေ့သြ၊_။_သိပ္ပံမောင်ဝကဒီ

Chunk line #2

မှာတင်ပန်းသည်စာ_မူကိုရပ်ခဲ့တယ်_။

Chunks saved to ./exp2/ma_thaung.chunk4.txt

real 0m1.494s

user 0m6.136s

sys 0m0.397s

No. of chunks: 126

Chunk line #1

ပန်း၊_သည်၊_မ၊_သောင်း၊_က_အ၊_သက်၊_က၊_၁၊_၆၊_နှစ်

Chunk line #2

၊_ယဉ်၊_စ_စ၊_နဲ့၊_နု၊_ပျို၊_မူ_ခြင်း၊_မှာ၊_မ၊_သိန်း၊_ထက်_အ

Chunk line #3

```

ပုံ | ကြီး_ သာ | သ | ပေါ့_ ။ | ဒီ_ တော့_ တက္က_ သိုလ်_ ကျောင်း_ သား_ တွေ | က | ပန်း | သည် | မ | သောင်း
Chunk line #4
ဆိုင် | မှာ | ပြောင်း | ပြီး | ပန်း | ဝယ် | ကြ_ ၊ | စ | ကား | တွေ
Chunk line #5
ဖောင် | ဖွဲ့ | ကြ_ တာ_ ပေါ့ | ။ | မ | သိန်း | ပန်း | ဆိုင်_ အ_ ရင်_ လို_ မ_ ရောင်း_ ရ | တော့ | ဘဲ
Chunk line #6
ခြောက် | ကပ်_ လာ_ တာ_ ပေါ့_ ။ | ဒီ | လို | နဲ့ | တ | နေ့ | သူ | ပန်း | ဆိုင် | နား
Chunk line #7
ကို | လင် | မ_ ယား_ နှစ်_ ယောက်_ က_ လေး_ လေး | လက် | ဆွဲ_ ပြီး_ ရောက်_ လာ | ။_ အ_ မျိုး_ သား_ ပ
↪ ဖြစ် | သူ | က
| တပ် | ထား
Chunk line #8
တဲ့ | မျက် | မှန် | ချွတ် | လိုက် | ပြီး | ကျ | နေ့_ မှတ် | မိ
Chunk line #9
လား | မေး | ။ | မောင် | သိန်း | ခိုင် | ဖြစ် | နေ | ။ | ပန်း
Chunk line #10
သည် | မ | သိန်း_ နဲ့_ ယော_ ကျ်း_ ဖြစ် | သူ | ကို | သိန်း | ခိုင် | တို့_ စ_ ကား | တွေ | တ
Chunk line #11
ရင်း | တ | နှီး | ဖောင် | ဖွဲ့ | နေ_ ကြ | တာ_ ကြ | ည့် | ပြီး_ ဇ_ နီး_ ဖြစ်_ သူ | က
Chunk line #12
အံ့ | တွေ | ဩ | ။ | သိပ္ပံ | မောင် | ဝ_ က_ ဒီ | မှာ | တင် | ပန်း
Chunk line #13
သည် | စာ | မူ | ကို_ ရပ် | ခဲ့ | တယ်_ ။
Chunks saved to ./exp2/ma_thaung.chunk5.txt

real    0m1.537s
user    0m6.211s
sys     0m0.396s

```

0.12 Check exp2 Folder

[46]: `!tree ./exp2`

```

./exp2
  ma_thaung.chunk1.txt
  ma_thaung.chunk2.txt
  ma_thaung.chunk3.txt
  ma_thaung.chunk4.txt
  ma_thaung.chunk5.txt
  tst2.distances-eg1.pdf
  tst2.distances-eg1.png
  tst2.distances-eg2.pdf
  tst2.distances-eg2.png
  tst2.distances-eg3.pdf
  tst2.distances-eg3.png

```

```
tst2.distances-eg4.pdf
tst2.distances-eg4.png
tst2.distances-eg5.pdf
tst2.distances-eg5.png
```


1 directory, 15 files

0.13 Check Output Grpahs

```
[40]: from IPython.display import Image

# Display the PNG image
Image(filename='./exp2/tst2.distances-eg1.png')
```


[40]:



```
[41]: from IPython.display import Image


# Display the PNG image
Image(filename='./exp2/tst2.distances-eg2.png')
```

[41]:



```
[44]: from IPython.display import Image  
  
# Display the PNG image  
Image(filename='./exp2/tst2.distances-eg3.png')
```

[44]:



[]: