

SentencePiece_tutorial

July 25, 2026

1 Subword Segmentation Tutorial

1.1 Ye Kyaw Thu, Language Understanding Lab, Myanmar

1.2 Date: 25 July 2026

SentencePiece ကို သုံးပြီး မြန်မာစာ စာကြောင်းတွေကို subword level ဖြတ်တာကို လက်တွေ့ လုပ်ကြည့်ကြရအောင်။

SentencePiece Github link: <https://github.com/google/sentencepiece>

1.3 Python Library Installation

```
[1]: %cd /home/ye/aif2/word-seg/sub-word
```

```
/home/ye/aif2/word-seg/sub-word
```

```
[2]: !pip install sentencepiece
```

error: externally-managed-environment

- × This environment is externally managed
- > To install Python packages system-wide, try apt install python3-xyz, where xyz is the package you are trying to install.

If you wish to install a non-Debian-packaged Python package, create a virtual environment using `python3 -m venv path/to/venv`. Then use `path/to/venv/bin/python` and `path/to/venv/bin/pip`. Make sure you have `python3-full` installed.

If you wish to install a non-Debian packaged Python application, it may be easiest to use `pipx install xyz`, which will manage a virtual environment for you. Make sure you have `pipx` installed.

See `/usr/share/doc/python3.12/README.venv` for more information.

note: If you believe this is a mistake, please contact your Python installation or OS distribution provider. You can override this, at the risk of breaking your Python installation or OS, by passing `--break-system-packages`.

hint: See PEP 668 for the detailed specification.

```
[3]: !pip install sentencepiece --break-system-packages
```

```
Defaulting to user installation because normal site-packages is not writeable
Requirement already satisfied: sentencepiece in
/home/ye/.local/lib/python3.12/site-packages (0.2.0)
```

1.4 Import Testing

```
[4]: import sentencepiece as spm
```

```
[5]: print(spm.__version__)
```

```
0.2.0
```

1.5 Small Data Preparation

```
[6]: !mkdir small_data
```

```
[7]: %cd small_data
```

```
/home/ye/aif2/word-seg/sub-word/small_data
```

```
[8]: !wget https://github.com/ye-kyaw-thu/myPOS/raw/refs/heads/master/
      ↪ corpus-draft-ver-1.0/mypos-dver.1.0.word.txt
```

```
--2026-07-25 17:57:51-- https://github.com/ye-kyaw-
thu/myPOS/raw/refs/heads/master/corpus-draft-ver-1.0/mypos-dver.1.0.word.txt
Resolving github.com (github.com)... 20.205.243.166
Connecting to github.com (github.com)|20.205.243.166|:443... connected.
HTTP request sent, awaiting response... 302 Found
Location: https://raw.githubusercontent.com/ye-kyaw-
thu/myPOS/refs/heads/master/corpus-draft-ver-1.0/mypos-dver.1.0.word.txt
[following]
```

```
--2026-07-25 17:57:51-- https://raw.githubusercontent.com/ye-kyaw-
thu/myPOS/refs/heads/master/corpus-draft-ver-1.0/mypos-dver.1.0.word.txt
Resolving raw.githubusercontent.com (raw.githubusercontent.com)...
185.199.110.133, 185.199.108.133, 185.199.111.133, ...
Connecting to raw.githubusercontent.com
(raw.githubusercontent.com)|185.199.110.133|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 3466670 (3.3M) [application/octet-stream]
Saving to: 'mypos-dver.1.0.word.txt'
```

```
mypos-dver.1.0.word 100%[=====>] 3.31M --.-KB/s in 0.03s
```

```
2026-07-25 17:57:52 (95.1 MB/s) - 'mypos-dver.1.0.word.txt' saved
[3466670/3466670]
```

```
[9]: !head ./mypos-dver.1.0.word.txt
```

ယခု လ တွင် ပျားရည် နှင့် ပျားဖယောင်း များ ကို စုဆောင်း ကြ သည် ဟု ခန့်မှန်း နိုင်
သည် ။
အခန်းခ ထဲ မှာ ထည့် လိုက် ပါ ။
ဆရာကြီး ဦးစိန် ၏ မြန်မာ အထက်တန်း ကျောင်း မှ ၉ တန်း အောင်မြင် ခဲ့ ပြီး မင်းလှ
မြို့ နော်မံ ကျောင်း မှ အလယ်တန်း ဆရာ ဖြစ် အောင်မြင် ခဲ့ ၏ ။
ရှစ်လေးလုံး လှုပ်ရှား မှု တွင် တက်ကြွ စွာ ပါဝင် ခဲ့ သလို ၊ ဗမာ နိုင်ငံ လုံး
ဆိုင်ရာ ကျောင်းသား သမဂ္ဂ များ အဖွဲ့ချုပ် မှာ လည်း တက်ကြွ စွာ ပါဝင် လှုပ်ရှား ခဲ့
သည် ။
ဗြိတိသျှ တပ် များ သည် ဂျပန် များ ၏ ငါး ဖမ်း အိမ် ၃၀၀၀၀၀ ခန့် တွင် အလုပ်
လုပ်ကိုင် နေ ကြ ရ သည် ။
ဗမာ မှာ လူ များစု ဗမာ မျိုးနွယ်စု ၏ ခေါ် ရာတွင် တရားဝင် ခေါ် သော အသုံး ဖြစ် သည်
။
၂၀ ရာစု ၏ ပထမ ပိုင်း ရာစုနှစ် တဝက် တွင် အိန္ဒိယ အမျိုးသား ကွန်ဂရက် နှင့် အခြား
နိုင်ငံ ရေး အဖွဲ့အစည်း များ မှ တစ် နိုင်ငံ လုံး အတိုင်းအတာ ဖြင့် လွတ်လပ် ရေး
ကြိုးပမ်း မှု ကို စတင် ခဲ့ သည် ။
၎င်း ဘာသာ အခွဲ ငယ် များ သည် အများစု မှ ခွဲထွက် လာ ကြ ပြီး ၊ အစ္စလာမ် မှ ကွဲကွာ
ထား သည့် ဗီဒါတ် မွန်မံ ပြင်ဆင် ချက် များ နှင့် အစွန်းရောက် နိုင်ငံ ရေး အမြင်
များ ကို သွတ်သွင်း လက်ခံ သုံးစွဲ လာ ကြ သည် ။
ပဉ္စမ အကြိမ် ၁ ၊ ဩဂုတ် ၊ ၂၀၀၂ ၊ ရာပြည့် စာအုပ်တိုက် ထုတ် စာဆို တော် များ
အတ္ထုပ္ပတ္တိ က ရွှေ့ဒေါင်း ၁၂၅၁ ၁၃၃၅ အကြောင်း မောင်သုတ အမည်ခံ ဗိုလ်မှူးဘသောင်း
မဟာ ဝိဇ္ဇာ ၊ ရွှေ တံဆိပ် ရ ဖခင် ဦးဧရာ သည် သီပေါ မင်း လက်ထက် တွင် လွှတ်တော် စာရေး
အဖြစ် အမှုထမ်း ခဲ့ ဖူး သည် ။
အချို့ မွန် ကျောက်စာ တို့ ၌ မကုဋ မင်း ဟု လည်း ခေါ် သည် ။

```
[10]: !wc ./mypos-dver.1.0.word.txt
```

```
11000 239598 3466670 ./mypos-dver.1.0.word.txt
```

1.6 Big Data Preparation

```
[11]: %pwd
```

```
[11]: '/home/ye/aif2/word-seg/sub-word/small_data'
```

```
[12]: %cd ..
```

```
/home/ye/aif2/word-seg/sub-word
```

```
[13]: !mkdir big_data
```

```
[14]: %cd big_data/
```

```
/home/ye/aif2/word-seg/sub-word/big_data
```

```
[15]: !wget https://github.com/ye-kyaw-thu/myPOS/raw/refs/heads/master/corpus-ver-3.0/
      ↪corpus/mypos-ver.3.0.shuf.nopipe.txt
```

```
--2026-07-25 18:01:36-- https://github.com/ye-kyaw-thu/myPOS/raw/refs/heads/master/corpus-ver-3.0/corpus/mypos-ver.3.0.shuf.nopipe.txt
Resolving github.com (github.com)... 20.205.243.166
Connecting to github.com (github.com)|20.205.243.166|:443... connected.
HTTP request sent, awaiting response... 302 Found
Location: https://raw.githubusercontent.com/ye-kyaw-thu/myPOS/refs/heads/master/corpus-ver-3.0/corpus/mypos-ver.3.0.shuf.nopipe.txt
[following]
--2026-07-25 18:01:37-- https://raw.githubusercontent.com/ye-kyaw-thu/myPOS/refs/heads/master/corpus-ver-3.0/corpus/mypos-ver.3.0.shuf.nopipe.txt
Resolving raw.githubusercontent.com (raw.githubusercontent.com)...
185.199.109.133, 185.199.111.133, 185.199.108.133, ...
Connecting to raw.githubusercontent.com
(raw.githubusercontent.com)|185.199.109.133|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 9581544 (9.1M) [application/octet-stream]
Saving to: 'mypos-ver.3.0.shuf.nopipe.txt'

mypos-ver.3.0.shuf. 100%[=====>] 9.14M 33.3MB/s in 0.3s

2026-07-25 18:01:38 (33.3 MB/s) - 'mypos-ver.3.0.shuf.nopipe.txt' saved
[9581544/9581544]
```

```
[16]: !head ./mypos-ver.3.0.shuf.nopipe.txt
```

```
၁၉၆၂/num ခုနှစ်/n ခန့်မှန်း/v သန်းခေါင်စာရင်း/n အရ/ppm လူဦးရေ/n ၁၁၅၉၃၁/num
ယောက်/part ရှိ/v သည်/ppm ။/punc
လူ/n တိုင်း/part တွင်/ppm သင့်မြတ်/v လျော်ကန်/v စွာ/part ကန့်သတ်/v ထား/part
သည့်/part အလုပ်/n လုပ်/v ချိန်/n အပြင်/conj ၊/punc လစာ/n နှင့်တကွ/conj အခါ/n
ကာလ/n အားလျော်စွာ/ppm သတ်မှတ်/v ထား/part သည့်/part အလုပ်/n အားလပ်ရက်/n များ/
↪part
ပါဝင်/v သည့်/part အနားယူခွင့်/n နှင့်/conj အားလပ်ခွင့်/n ခံစားပိုင်ခွင့်/n ရှိ/v
သည်/ppm ။/punc
ဤ/adj နည်း/n ကို/ppm စစ်ယူ/v သော/part နည်း/n ဟု/part ခေါ်/v သည်/ppm ။/punc
စာပြန်ပွဲ/n ဆို/v တာ/part က/ppm အာဂုံဆောင်/v အလွတ်ကျက်/v ထား/part တဲ့/part
ပိဋကတ်သုံးပုံ/n စာပေ/n တွေ/part ကို/ppm စာစစ်/v သံဃာတော်ကြီး/n တွေ/part ရဲ့/ppm
ရှေ့/n မှာ/ppm အလွတ်/adv ပြန်/v ပြီး/part ရွတ်ပြ/v ရ/part တာ/part ပေါ့/part
။/pron မှာ/ppm ကျွန်တော့်/pron သက်သေခံကတ်/n ပါ/part ။/punc
၂၀/num ရာစု/n မြန်မာ့/n သမိုင်း/n သန်းဝင်းလှိုင်/n ၊/punc ၂၀၀၉/num ခု/part
၊/punc မေ/n လ/n ၊/punc ကံကော်ဝတ်ရည်/n စာပေ/n ။/punc
```

ကျွန်တော်/pron မျက်မှန်/n တစ်/tn လက်/part လုပ်/v ချင်/part ပါ/part တယ်/ppm
 //punc
 ကျွန်တော်/pron တို့/part က/ppm ဒီ/pron အမှု/n ရဲ့/ppm ကြံရာပါ/n ကို/ppm ဖမ်းမိ/v
 ဖို့/part ကြိုးစား/v ခဲ့/part တယ်/ppm //punc
 ကလေး/n မီးဖွား/v ဖို့/part ခန့်မှန်း/adj ရက်/n က/ppm ဘယ်တော့/pron ပါ/part
 လဲ/part //punc
 အရိုးရှင်းဆုံး/adj ကာဗိုဟိုက်ဒရိတ်/n မှာ/ppm ဂလူးကိုစ့်/n /punc ဂလက်တို့စ့်/n
 /punc ဖရပ်တို့စ့်/n စသည့်/part မိုနိုဆက်ကရိုက်/n များ/part ဖြစ်/v သည်/ppm //punc

1.7 Download Code for Removing POS-tags

```
[17]: !wget https://github.com/ye-kyaw-thu/myPOS/raw/refs/heads/master/
      ↪corpus-draft-ver-1.0/mk-wordtag.pl
```

```
--2026-07-25 18:02:32-- https://github.com/ye-kyaw-
thu/myPOS/raw/refs/heads/master/corpus-draft-ver-1.0/mk-wordtag.pl
Resolving github.com (github.com)... 20.205.243.166
Connecting to github.com (github.com)|20.205.243.166|:443... connected.
HTTP request sent, awaiting response... 302 Found
Location: https://raw.githubusercontent.com/ye-kyaw-
thu/myPOS/refs/heads/master/corpus-draft-ver-1.0/mk-wordtag.pl [following]
--2026-07-25 18:02:32-- https://raw.githubusercontent.com/ye-kyaw-
thu/myPOS/refs/heads/master/corpus-draft-ver-1.0/mk-wordtag.pl
Resolving raw.githubusercontent.com (raw.githubusercontent.com)...
185.199.111.133, 185.199.108.133, 185.199.110.133, ...
Connecting to raw.githubusercontent.com
(raw.githubusercontent.com)|185.199.111.133|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 3967 (3.9K) [text/plain]
Saving to: 'mk-wordtag.pl'
```

```
mk-wordtag.pl      100%[=====>]    3.87K  --.-KB/s    in 0s
```

```
2026-07-25 18:02:33 (48.3 MB/s) - 'mk-wordtag.pl' saved [3967/3967]
```

1.8 Removing POS-tags of Big Data

```
[18]: !perl ./mk-wordtag.pl ./mypos-ver.3.0.shuf.nopipe.txt "\/" w > big_corpus.txt
```

```
[19]: !head ./big_corpus.txt
```

၁၉၆၂ ခုနှစ် ခန့်မှန်း သန်းခေါင်စာရင်း အရ လူဦးရေ ၁၁၅၉၃၁ ယောက် ရှိ သည် ။
 လူ တိုင်း တွင် သင့်မြတ် လျော်ကန် စွာ ကန့်သတ် ထား သည့် အလုပ် လုပ် ချိန် အပြင် ၊
 လစာ နှင့်တကွ အခါ ကာလ အားလျော်စွာ သတ်မှတ် ထား သည့် အလုပ် အားလပ်ရက် များ ပါဝင်
 သည့် အနားယူခွင့် နှင့် အားလပ်ခွင့် ခံစားပိုင်ခွင့် ရှိ သည် ။
 ဤ နည်း ကို စစ်ယူ သော နည်း ဟု ခေါ် သည် ။

စာပြန်ပွဲ ဆို တာ က အာဂုံဆောင် အလွတ်ကျက် ထား တဲ့ ပိဋကတ်သုံးပုံ စာပေ တွေ ကို စာစစ် သံဃာတော်ကြီး တွေ ရဲ့ ရှေ့ မှာ အလွတ် ပြန် ပြီး ရွတ်ပြ ရ တာ ပေါ့ ။
 ဒီ မှာ ကျွန်တော့် သက်သေခံကတ် ပါ ။
 ၂၀ ရာစု မြန်မာ့ သမိုင်း သန်းဝင်းလှိုင် ၊ ၂၀၀၉ ခု ၊ မေ လ ၊ ကံကော်ဝတ်ရည် စာပေ ။
 ကျွန်တော် မျက်မှန် တစ် လက် လုပ် ချင် ပါ တယ် ။
 ကျွန်တော် တို့ က ဒီ အမှု ရဲ့ ကြံရာပါ ကို ဖမ်းမိ ဖို့ ကြိုးစား ခဲ့ တယ် ။
 ကလေး မီးဖွား ဖို့ ခန့်မှန်း ရက် က ဘယ်တော့ ပါ လဲ ။
 အရိုးရှင်းဆုံး ကာဗိုဟိုက်ဒရိတ် မှာ ဂလူးကို့စ် ၊ ဂလက်တို့့စ် ၊ ဖရပ်တို့့စ် စသည့်
 မိုနိုဆက်ကရိုက် များ ဖြစ် သည် ။

1.9 Building SentencePiece Model with Small Data

```
[30]: %pwd
```

```
[30]: '/home/ye/aif2/word-seg/sub-word/big_data'
```

```
[31]: %cd /home/ye/aif2/word-seg/sub-word/small_data
```

```
/home/ye/aif2/word-seg/sub-word/small_data
```

```
[32]: import sentencepiece as spm

# 1. Train a model directly from a raw text file.
# (No pre-tokenization or language-specific preprocessing required!)
spm.SentencePieceTrainer.train(
    input='/home/ye/aif2/word-seg/sub-word/small_data/mypos-dver.1.0.word.txt',
    model_prefix='small',
    vocab_size=1000
)
```

```
sentencepiece_trainer.cc(78) LOG(INFO) Starts training with :
trainer_spec {
  input: /home/ye/aif2/word-seg/sub-word/small_data/mypos-dver.1.0.word.txt
  input_format:
  model_prefix: small
  model_type: UNIGRAM
  vocab_size: 1000
  self_test_sample_size: 0
  character_coverage: 0.9995
  input_sentence_size: 0
  shuffle_input_sentence: 1
  seed_sentencepiece_size: 1000000
  shrinking_factor: 0.75
  max_sentence_length: 4192
  num_threads: 16
  num_sub_iterations: 2
  max_sentencepiece_length: 16
```

```

split_by_unicode_script: 1
split_by_number: 1
split_by_whitespace: 1
split_digits: 0
pretokenization_delimiter:
treat_whitespace_as_suffix: 0
allow_whitespace_only_pieces: 0
required_chars:
byte_fallback: 0
vocabulary_output_piece_score: 1
train_extremely_large_corpus: 0
seed_sentencepieces_file:
hard_vocab_limit: 1
use_all_vocab: 0
unk_id: 0
bos_id: 1
eos_id: 2
pad_id: -1
unk_piece: <unk>
bos_piece: <s>
eos_piece: </s>
pad_piece: <pad>
unk_surface:
enable_differential_privacy: 0
differential_privacy_noise_level: 0
differential_privacy_clipping_threshold: 0
}
normalizer_spec {
  name: nmt_nfkc
  add_dummy_prefix: 1
  remove_extra_whitespace: 1
  escape_whitespace: 1
  normalization_rule_tsv:
}
denormalizer_spec {}
trainer_interface.cc(353) LOG(INFO) SentenceIterator is not specified. Using
MultiFileSentenceIterator.
trainer_interface.cc(185) LOG(INFO) Loading corpus: /home/ye/aif2/word-seg/sub-
word/small_data/mypos-dver.1.0.word.txt
trainer_interface.cc(380) LOG(WARNING) Found too long line (7208 > 4192).
trainer_interface.cc(382) LOG(WARNING) Too long lines are skipped in the
training.
trainer_interface.cc(383) LOG(WARNING) The maximum length can be changed with
--max_sentence_length=<size> flag.
trainer_interface.cc(409) LOG(INFO) Loaded all 10999 sentences
trainer_interface.cc(416) LOG(INFO) Skipped 1 too long sentences.
trainer_interface.cc(425) LOG(INFO) Adding meta_piece: <unk>
trainer_interface.cc(425) LOG(INFO) Adding meta_piece: <s>

```

```

trainer_interface.cc(425) LOG(INFO) Adding meta_piece: </s>
trainer_interface.cc(430) LOG(INFO) Normalizing sentences...
trainer_interface.cc(539) LOG(INFO) all chars count=1322904
trainer_interface.cc(550) LOG(INFO) Done: 99.9524% characters are covered.
trainer_interface.cc(560) LOG(INFO) Alphabet size=123
trainer_interface.cc(561) LOG(INFO) Final character coverage=0.999524
trainer_interface.cc(592) LOG(INFO) Done! preprocessed 10999 sentences.
unigram_model_trainer.cc(265) LOG(INFO) Making suffix array...
unigram_model_trainer.cc(269) LOG(INFO) Extracting frequent sub strings...
node_num=657135
unigram_model_trainer.cc(312) LOG(INFO) Initialized 31704 seed sentencepieces
trainer_interface.cc(598) LOG(INFO) Tokenizing input sentences with whitespace:
10999
trainer_interface.cc(609) LOG(INFO) Done! 15897
unigram_model_trainer.cc(602) LOG(INFO) Using 15897 sentences for EM training
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=0 size=13258 obj=10.7515
num_tokens=35413 num_tokens/piece=2.67107
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=1 size=10577 obj=9.14298
num_tokens=35615 num_tokens/piece=3.36721
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=0 size=7919 obj=9.12974
num_tokens=37282 num_tokens/piece=4.70792
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=1 size=7889 obj=9.08326
num_tokens=37305 num_tokens/piece=4.72874
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=0 size=5914 obj=9.16186
num_tokens=40446 num_tokens/piece=6.83903
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=1 size=5906 obj=9.13431
num_tokens=40454 num_tokens/piece=6.84964
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=0 size=4429 obj=9.27333
num_tokens=44536 num_tokens/piece=10.0555
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=1 size=4429 obj=9.23693
num_tokens=44534 num_tokens/piece=10.0551
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=0 size=3321 obj=9.42803
num_tokens=48893 num_tokens/piece=14.7224
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=1 size=3321 obj=9.38579
num_tokens=48893 num_tokens/piece=14.7224
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=0 size=2489 obj=9.6492
num_tokens=53590 num_tokens/piece=21.5307
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=1 size=2489 obj=9.59065
num_tokens=53588 num_tokens/piece=21.5299
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=0 size=1866 obj=9.94588
num_tokens=58880 num_tokens/piece=31.5541
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=1 size=1866 obj=9.86452
num_tokens=58880 num_tokens/piece=31.5541
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=0 size=1399 obj=10.3618
num_tokens=64735 num_tokens/piece=46.2723
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=1 size=1399 obj=10.2555
num_tokens=64736 num_tokens/piece=46.2731
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=0 size=1100 obj=10.7101

```



```

num_tokens=69472 num_tokens/piece=63.1564
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=1 size=1100 obj=10.6029
num_tokens=69472 num_tokens/piece=63.1564
trainer_interface.cc(687) LOG(INFO) Saving model: small.model
trainer_interface.cc(699) LOG(INFO) Saving vocabs: small.vocab

```

[33]: `!ls -lh small*`

```

-rw-rw-r-- 1 ye ye 253K Jul 25 18:17 small.model
-rw-rw-r-- 1 ye ye  22K Jul 25 18:17 small.vocab

```

[34]: `!wc ./small.vocab`

```

1000  2000 22197 ./small.vocab

```

[35]: `!cat ./small.vocab`

```

<unk>    0
<s>      0
</s>    0
-2.24937
သည်     -3.57686
။       -3.66496
အ       -3.83824
့       -4.06821
များ    -4.16473
ကို     -4.28226
၊       -4.5687
တွင်    -4.62469
သော     -4.69374
ဖြစ်    -4.77428
မ       -4.84781
၏      -4.87207
နှင့်    -4.87389
ခဲ      -4.90358
က       -4.96065
တို့     -4.97037
ရှိ      -4.97472
ရ       -5.00282
မ       -5.0098
း       -5.10855
န်      -5.13147
ပါ      -5.1319
အ       -5.20592
ရ       -5.21639
က       -5.25077
ကြ      -5.25318

```

တစ်	-5.3779
မှ	-5.37934
တ	-5.37984
မှာ	-5.39022
၍	-5.4315
ပြီး	-5.43792
န	-5.46208
ဝ	-5.49165
ရေး	-5.5181
နိုင်ငံ	-5.53441
က်	-5.56787
လ	-5.57091
လ	-5.61708
မှု	-5.64306
ဖ	-5.64454
နေ	-5.67234
င်	-5.67403
င်း	-5.68138
ခြင်း	-5.72356
သ	-5.72502
သ	-5.76551
ီ	-5.77594
ို	-5.79063
ာ	-5.79536
နိုင်	-5.81204
ထို	-5.81378
ွ	-5.82951
သည့်	-5.83113
တ	-5.84173
ပ	-5.84902
သူ	-5.84934
ို	-5.8505
စ	-5.8835
ြင့်	-5.90612
လာ	-5.91746
လည်း	-5.91917
မြန်မာ	-5.92617
ိ	-5.93655
စ်	-5.94037
ူ	-5.95312
ိ	-5.95843
မ်း	-5.96925
ဗို	-5.97159

ောင်	-5.99795
သို့	-6.02223
ော	-6.03978
ရန်	-6.04401
ဆ	-6.04457
ရာ	-6.05107
ဟု	-6.05519
သား	-6.06524
ယ	-6.08277
ပ်	-6.1022
ချ	-6.1033
ခ	-6.10364
လူ	-6.10828
ထား	-6.12129
ား	-6.13493
ဘ	-6.13579
ရှိ	-6.1457
ေ	-6.16353
မြို့	-6.16934
ခုနှစ်	-6.17421
မြ	-6.18143
င်	-6.19073
စ	-6.19495
ဂ	-6.20767
ယ်	-6.22965
ပေး	-6.23612
ခု	-6.2436
လေ	-6.24648
နှစ်	-6.25714
ပ	-6.26815
ဒ	-6.28512
ကျ	-6.29428
ခံ	-6.31232
မည်	-6.33407
ဲ	-6.34835
ဟ	-6.35244
မျိုး	-6.36101
အား	-6.36873
ဇ	-6.37749
ဦး	-6.37769
ကြီး	-6.39677
ထ	-6.39904
န်း	-6.41054
ဖ	-6.41465

စွာ	-6.41501
ဆုံး	-6.42487
ခြား	-6.45398
ကြီး	-6.45411
ကောင်း	-6.46484
e	-6.47002
စား	-6.48437
ကျ	-6.50285
ံ	-6.5029
ရပ်	-6.50974
ိတ်	-6.51372
သွား	-6.51799
တယ်	-6.52092
တော်	-6.52298
တွက်	-6.53069
ပြု	-6.53299
၍	-6.53814
ယူ	-6.54714
လေး	-6.56312
ဆောင်	-6.5724
သာ	-6.58014
ဆို	-6.58062
ီး	-6.59065
o	-6.5918
ွေး	-6.59319
ရာ	-6.59903
၁	-6.60397
ပင်	-6.61263
o	-6.61381
ေး	-6.6149
စစ်	-6.63945
ပညာ	-6.64356
စု	-6.64529
ဆို	-6.65216
ျ	-6.67312
ွန်	-6.67761
၂	-6.67768
ဘာသာ	-6.67807
ဆ	-6.67929
a	-6.68556
ူး	-6.68692
လက်	-6.69652
ျက်	-6.7011
အဖြစ်	-6.71168

တ်	-6.73776
ဝါ	-6.74684
တည်	-6.75131
လား	-6.75292
ပေ	-6.7539
စ	-6.75628
တာ	-6.76137
ခ	-6.76564
သက်	-6.77822
ခေါ်	-6.7849
လျှင်	-6.78927
t	-6.79275
i	-6.81481
s	-6.82896
အတွင်း	-6.83574
တွေ့	-6.83878
၆	-6.83957
ောက်	-6.84183
အဖွဲ့	-6.84728
အခါ	-6.84894
ပြင်	-6.85951
ဝင်	-6.86842
ဗေဒ	-6.88448
ဗ	-6.89268
၇	-6.89309
ဟူ	-6.89674
ိုင်း	-6.89799
ပြည်	-6.89837
ြ	-6.89997
တောင်	-6.90562
စေ	-6.90945
လို	-6.91287
ပေါ်	-6.91401
စဉ်	-6.91443
ိုက်	-6.91461
စီ	-6.92033
လိုက်	-6.92236
ပြ	-6.93792
နယ်	-6.93942
သစ်	-6.93975
စာ	-6.9418
၂	-6.94492
မူ	-6.94737

d	-6.94773
ကြောင်း	-6.94829
ဒေသ	-6.97718
ဘက်	-6.97811
ပြည်	-6.98415
ရက်	-6.99262
ဇ	-6.99426
ရှင်	-7.00125
ွေ	-7.00191
ရေ	-7.00322
ကာ	-7.00423
ည	-7.00664
ကုန်	-7.00936
အရ	-7.01692
လဲ	-7.02465
စိုးရ	-7.02701
ကမ္ဘာ	-7.02827
ပုံ	-7.03415
ပေါင်း	-7.03955
ကြာ	-7.04049
ရေ	-7.04264
မ်	-7.06595
ပြ	-7.07578
ဦး	-7.07684
ဒီ	-7.077
u	-7.07936
ချုပ်	-7.08095
ပြန်	-7.08833
တိ	-7.09189
ခင်	-7.09666
တင်	-7.09773
r	-7.1155
m	-7.11588
တဲ့	-7.11702
ပွဲ	-7.11782
နေ	-7.12093
သို့	-7.12218
ဆင်	-7.1229
ံ	-7.12363
ပိုင်း	-7.12588
တိုင်း	-7.1261
သော	-7.13476
ချက်	-7.1349

မြင်	-7.13538
သော်လည်း	-7.14699
မင်း	-7.14794
ုတ်	-7.15248
လူမျိုး	-7.15378
အိန္ဒိယ	-7.15378
လေ့လာ	-7.15408
လို	-7.15422
ဂြိုဟ်	-7.15676
ိုင်	-7.15958
စကား	-7.16394
တိုက်	-7.16998
၄	-7.17205
အမည်	-7.17512
ွတ်	-7.18018
ပါဝင်	-7.18543
ဗ	-7.18723
ကျောင်း	-7.18972
မာ	-7.20877
သိ	-7.20908
နား	-7.21001
တတ်	-7.21742
ဘယ်	-7.22519
ကြာ	-7.22643
ါ	-7.22703
လုပ်	-7.22747
စာ	-7.23311
လည်	-7.24029
နေရာ	-7.24916
ဆက်	-7.26255
ပေါ်	-7.26377
ကြောင့်	-7.26404
ဥ	-7.27145
ယာ	-7.27534
၃	-7.29256
နေ့	-7.30828
ကြ	-7.30867
ချိန်	-7.31094
သတ္တ	-7.3111
တွေ	-7.31241
ပါး	-7.313
တူ	-7.3162

တီ	-7.32344
လုံး	-7.32592
သုံး	-7.32785
c	-7.32963
နာ	-7.33408
လက်	-7.34045
ယင်း	-7.34062
l	-7.34267
၃	-7.3439
ကား	-7.34393
နီ	-7.34472
ခေတ်	-7.34871
g	-7.35017
အချို့	-7.35414
အများ	-7.35882
cယ်	-7.35946
h	-7.36246
ရွက်	-7.36489
ရောက်	-7.36734
ဆိုင်	-7.37563
သီး	-7.37605
ဂျ	-7.38129
လောက်	-7.38257
လုပ်ငန်း	-7.38327
မျှ	-7.3902
နည်း	-7.39445
ဘာ	-7.39463
ပေါင်း	-7.39513
ရေ	-7.39521
သဖ	-7.39571
အထိ	-7.39789
c	-7.40804
အားဖြ	-7.41214
မှု	-7.41453
ဏ	-7.41677
ခြေ	-7.41734
ုပ်	-7.4206
ငှက်	-7.42136
ပြောင်း	-7.42238
အချိန်	-7.43438
ယခ	-7.43553
ထောင်	-7.43585
ငွေ	-7.43805

ပေါက်	-7.43894
ဆောင်	-7.43938
လာ	-7.44118
အောင်	-7.44445
ရောက်	-7.44779
မှတ်	-7.45039
ခန့်	-7.45316
မှိုလ်ချုပ်	-7.45694
စပ်	-7.45838
ဝင်	-7.46175
သန်း	-7.46201
ချင်း	-7.46427
တို	-7.46518
မြောက်	-7.46646
တာ	-7.46946
လွတ်လပ်	-7.47317
ပြော	-7.4766
ကာ	-7.48087
မြေ	-7.48925
.	-7.50222
နောက်	-7.50231
နောက်	-7.50757
ိယ	-7.50789
လီ	-7.50898
နက်	-7.50935
ကိုယ်	-7.50966
အာ	-7.5102
အောက်	-7.51031
အရှေ့	-7.51067
သာ	-7.51318
တ္တ	-7.51461
ခွဲ	-7.51595
ချေ	-7.51824
ရီ	-7.51986
စနစ်	-7.52124
လဲ	-7.5226
ရင်	-7.52516
ဟုတ်	-7.52532
တန်း	-7.52668
ာတွင်	-7.52789
ပါ	-7.53067
စတင်	-7.53175

တော့	-7.53239
ထွက်	-7.5337
ရုတ်	-7.53638
ကဲ့	-7.53691
ထက်	-7.53774
အောင်ဆန်း	-7.54524
နှုန်း	-7.54964
y	-7.54964
၄	-7.55406
တိုင်	-7.55829
လုံး	-7.55871
တောင်	-7.57824
တန်	-7.586
ဆာ	-7.58607
စိတ်	-7.59251
သူ	-7.59272
နေထိုင်	-7.5948
ဂျပ	-7.59698
ကုန်	-7.60605
ထဲ	-7.60935
စီး	-7.61296
ဓာတ်	-7.61344
နဲ့	-7.61818
ဆက်	-7.61937
သို့သော်	-7.6207
မျှ	-7.62362
n	-7.62473
ပေး	-7.62525
ဓ	-7.62766
C	-7.62766
S	-7.62766
ကျွန်း	-7.628
အကြောင်း	-7.63284
လို့	-7.63879
in	-7.64321
ချင်	-7.65159
ပင်	-7.65388
ချက်	-7.65652
လယ်	-7.65669
နည်း	-7.66061
ပတ်	-7.66085
ထုတ်	-7.66489
လွန်	-7.66534

ပိုင်း -7.66865
 ငါး -7.66964
 မိ -7.67
 သေ -7.67159
 သေး -7.67242
 ပုံ -7.67632
 p -7.67657
 အုပ်ချုပ် -7.68671
 ရဲ -7.6887
 ကျောက် -7.69058
 ဒါ -7.69182
 ငှ -7.69577
 ကြည် -7.69875
 နှစ် -7.70834
 ရွှေ -7.71229
 စီးပွား -7.71233
 အသုံးပြု -7.71844
 ထူး -7.72212
 တည် -7.72342
 အင်္ဂလိပ် -7.72799
 ပထမ -7.72806
 အပင် -7.73037
 စုံ -7.7345
 ည်း -7.7379
 ထား -7.73798
 ပိုင် -7.7388
 ရည် -7.74485
 မြစ် -7.74531
 ပြီ -7.74982
 an -7.75075
 ကျော် -7.75324
 ကြောင့် -7.75376
 သင် -7.75407
 န်း -7.75431
 ရည် -7.75473
 တရား -7.75949
 ဗြိတိသျှ -7.76017
 ရိုး -7.76683
 စသည် -7.76726
 ပို -7.76937
 ခန်း -7.77332
 ပစ္စည်း -7.77666

ဒ်	-7.777
ar	-7.77908
အလွန်	-7.78534
ရင်း	-7.78841
မြင့်	-7.78854
ကို	-7.78927
ခေါင်း	-7.79947
လမ်း	-7.79951
တု	-7.79999
ဒီ	-7.80031
ဟုတ်	-7.80122
အနောက်	-7.80593
ပြည့်	-7.80621
၂၀၀	-7.80643
ဆင်း	-7.81458
ွဲ	-7.81872
လမ်း	-7.82178
ဖွဲ့စည်း	-7.822
အခြေခံ	-7.82205
နီ	-7.82209
ဘဲ	-7.82296
တစ်	-7.82316
အိမ်	-7.82825
တိုးတက်	-7.83365
ရှင်း	-7.83629
M	-7.83953
မိမိ	-7.83955
ထိ	-7.84011
၁၉၄	-7.84021
ပဲ	-7.84329
သိ	-7.84452
ယောက်	-7.84608
ကြည့်	-7.84762
ဘုရား	-7.8514
ဝန်း	-7.85685
လင်း	-7.86147
ရှု	-7.86341
သွယ်	-7.86353
မိုး	-7.86618
လ်	-7.86634
မန္တ	-7.86947
ရှေး	-7.86947
ည်	-7.87401

သံ	-7.87713
မှန်	-7.87828
နှံ	-7.8817
အဓိက	-7.8817
တိုက်	-7.88455
က်တမ်	-7.8848
ရုံး	-7.88483
ဝတ္ထု	-7.88788
အပ်	-7.88855
ဏ်	-7.889
b	-7.89409
ံ	-7.89527
ပန်း	-7.89661
ပြန်	-7.89725
တက္ကသိုလ်	-7.90034
ကွန်	-7.90244
ထွက်	-7.9044
ဖို	-7.90779
ကာလ	-7.90847
er	-7.91167
လေ့	-7.91572
ဖက်	-7.9162
ပြုလုပ်	-7.91944
ုံး	-7.92293
ထု	-7.92589
ဘူး	-7.92651
မေ	-7.92691
ဒုတ	-7.9322
၁၉	-7.93852
မိုင်	-7.9449
I	-7.94522
အစည်း	-7.94695
ညီ	-7.95182
မျောက်	-7.95182
နှစ်	-7.95238
ဆယ်	-7.95671
စံ	-7.95964
ပင်လယ်	-7.967
ထပ်	-7.96786
စော	-7.97098
ဆီ	-7.97348
မြင်း	-7.9755
ရုပ်	-7.97843

P	-7.97855
ကွက်	-7.97897
ဝေ:	-7.98009
ဆေး	-7.98429
ထုတ်လုပ်	-7.98575
ကျင်	-7.98585
ဗမာ	-7.98741
ဖော်	-7.99225
ဝေ	-7.9969
ရာစု	-7.9987
ဌာန	-7.9992
သဘော	-8.00397
အလုပ်	-8.00983
မယ်	-8.01552
ကွယ်	-8.02767
မတ်	-8.0285
A	-8.03432
ထင်ရှား	-8.04331
,	-8.04876
ြို:	-8.05374
သိပ္ပံ	-8.05606
အာရှ	-8.05606
သို့မ	-8.05781
on	-8.05818
ရွာ	-8.05892
ချို့	-8.06
ရာသီ	-8.06512
ဥ	-8.06819
ရံ	-8.0716
စိုက်ပျိုး	-8.07828
၁၈	-8.07881
ဆရာ	-8.08213
ကလေး	-8.08268
ပတ်	-8.08296
အပြင်	-8.08424
သတ်မှတ်	-8.08586
သွင်း	-8.08608
ပွား	-8.09314
ပို့	-8.09564
အား	-8.09833
စွ	-8.10098
၁၉၉	-8.10209
အရေး	-8.10374

ပြည်သူ -8.11059
 or -8.11242
 သီ -8.11506
 ဖော်ပြ -8.11657
 T -8.12426
 ကျွန်တော် -8.12428
 န်း -8.1243
 နိုင် -8.12435
 al -8.12852
 ၁၉၈ -8.13356
 အနက် -8.13439
 ရုံ -8.13602
 f -8.14007
 အမေရိကန် -8.14034
 နီ -8.14306
 ပေါ -8.14818
 ရော -8.15074
 လောက -8.1533
 ယဉ်ကျေး -8.15614
 ငြိမ် -8.15614
 ဈေး -8.15617
 သည် -8.1569
 ရိုက် -8.16015
 ဝန်ကြီး -8.16428
 အသုံး -8.16434
 ထုတ် -8.16461
 နိုင်ငံတော် -8.16849
 မြောက် -8.16851
 ဘုရင် -8.17247
 လျှော -8.17405
 သိမ်း -8.17937
 w -8.18073
 မျိုးသား -8.18384
 es -8.18597
 ဟာ -8.18659
 ကျမ်း -8.18808
 အာဏာ -8.18907
 သမား -8.18939
 ပြီး -8.19041
 စည်း -8.19207
 ထိုင် -8.1929
 B -8.19747
 ၁၉၆ -8.19886

ကျယ် -8.19996
 မွန် -8.20032
 အထက် -8.20646
 ဆံ -8.20949
 ထွန်း -8.21457
 စေရ -8.21938
 ထောက် -8.22211
 N -8.22311
 နာရီ -8.22326
 ဝိန်း -8.2245
 မြို့တော် -8.22604
 လုပ် -8.22682
 ဝက်ဝံ -8.23181
 ဝီတာ -8.23525
 ရှား -8.23784
 လိပ် -8.24096
 ဝတ် -8.24173
 မဲ့ -8.24336
 စင် -8.24764
 ဗုဒ္ဓ -8.24966
 ဖုံ -8.25137
 ဝါရီ -8.25203
 ယူဆ -8.25551
 ခေါင် -8.25771
 ခရီး -8.25841
 ဖွယ် -8.26347
 မောင် -8.26695
 ဝေါ် -8.26709
 ဥပဒေ -8.26736
 ဝင်ရောက် -8.26913
 သင့် -8.27192
 သတ် -8.27559
 နွဲ့ -8.27645
 မဟာ -8.27661
 များ -8.27915
 ုကြောင့် -8.28715
 ထင် -8.29408
 it -8.29674
 ကောက် -8.30167
 မဂ္ဂ -8.30423
 စွယ်စုံကျ -8.30423
 ဘဇ္ဇာ -8.30571
 စေ -8.30748

ဇီဝ -8.31376
 ချောင်း -8.31401
 သင် -8.3141
 ဘေးလုံး -8.31786
 ပျူ -8.31914
 at -8.32031
 လိုက် -8.32071
 ဖွဲ့ -8.32089
 ဖွား -8.32307
 ဂိတ်စ် -8.32323
 ထည့် -8.32476
 ဒေါ် -8.33267
 ယုံ -8.3336
 ရှာဖွေ -8.33398
 ဖွဲ့ -8.33435
 ကူး -8.33543
 ညီ -8.33733
 တာဝန် -8.34175
 ကုမ္ပဏီ -8.34251
 ပဏီ -8.34254
 သိုး -8.35266
 အတိုင်း -8.35323
 ပြောင်း -8.3582
 ဂျီ -8.35912
 သမိုင်း -8.36234
 င်ဘာ -8.36556
 ဟော -8.36708
 စိုး -8.36797
 စိုက် -8.37054
 သုံး -8.37215
 အမျိုးမျိုး -8.37222
 ပညာ -8.37227
 လော -8.37314
 ခဲ -8.37484
 D -8.38232
 ဂီ -8.38232
 ဘျ -8.38291
 သတ္တ -8.38323
 ပျ -8.38908
 ဖြစ်စေ -8.39094
 ကွာ -8.39884
 တပ်မတော် -8.40284
 စွမ်း -8.40531

ဇေ	-8.40563
en	-8.41147
လွတ်	-8.41325
'	-8.41325
ကိန်း	-8.41492
တရား	-8.41539
စာပေ	-8.41572
အချိုး	-8.41983
ic	-8.422
k	-8.42378
ဆိပ်	-8.42392
၁၇	-8.42444
ခေါ်	-8.42896
ကြံ	-8.43163
တွဲ	-8.43172
ဖြတ်	-8.43435
ကုန်း	-8.43488
ကွဲ	-8.4388
ွမ်း	-8.44388
အဓိပ္ပါယ်	-8.44517
L	-8.44517
ရိယာ	-8.44525
ဝက်	-8.45292
ပြား	-8.45399
အုပ်	-8.45628
le	-8.4643
ထည်	-8.46491
'	-8.46703
ဒေါ်	-8.46854
ဆွဲ	-8.47097
ထိုး	-8.47668
လက်ထ	-8.47712
ပြည်ထောင်စု	-8.47814
ကိစ္စ	-8.47817
ဝယ်	-8.48225
တံ	-8.48256
ာပူ	-8.48829
လျှောက်	-8.48938
အနီး	-8.49043
ကြွ	-8.49301
အကျိုး	-8.50074
ီးယား	-8.50084
အပူ	-8.50154

ကြီးမား -8.50228
 ကုလ -8.50956
 င် -8.51238
 စွဲ -8.51688
 စက် -8.52386
 ကိုးကွယ် -8.524
 အခြေအ -8.52422
 နောက်ဆုံး -8.52893
 သမ္မတ -8.53563
 ိုမို -8.53598
 ဖြူ -8.5375
 တောင်တန်း -8.53869
 ခြောက် -8.54762
 ငါ -8.55359
 ဖြေ -8.55705
 ရှမ်း -8.55958
 လျား -8.55963
 ဘိုင် -8.56018
 တိုး -8.56189
 လုံ -8.56429
 ပျက် -8.56632
 ဘူမိ -8.57177
 အရွယ် -8.57181
 သမီး -8.57251
 တွေ့ -8.58015
 ရောပ -8.58125
 အဲဒ -8.58394
 ဂျီဒီပီ -8.58412
 တည်ဆောက် -8.58414
 ကျေးဇူးပြု -8.5842
 ကြေး -8.58485
 ဝဝဝ -8.59372
 ကြေညာ -8.59662
 လှည့် -8.59662
 အခွင့်အ -8.59662
 လုပ်ကိုင် -8.59664
 ဘဝ -8.59693
 ညွှန်း -8.59928
 ိုက်ခိုက် -8.5994
 လောင် -8.60376
 e1 -8.60658
 ဌ -8.60928

ဒြပ်	-8.60928
မြတ်	-8.61028
နတ်	-8.61216
ုပ်စု	-8.62083
ရှာ	-8.62135
G	-8.6221
မျက်နှာ	-8.6221
ဓာတု	-8.6221
အချက်အ	-8.62241
၁၃	-8.62261
နေဖ	-8.6241
စာရင်း	-8.62426
ဖို့	-8.62694
ခတ်	-8.62977
စပါး	-8.63102
ပြိုင်	-8.6345
ဗဟို	-8.63511
၁၉၅	-8.63801
ချီ	-8.64023
is	-8.64185
ဇာတ	-8.64603
အပြား	-8.64701
သ	-8.64824
လှုပ်ရှား	-8.64824
ရှေ့	-8.64824
ဂုဏ်	-8.64824
ခြင်	-8.64907
ထံ	-8.6497
ဘဝ	-8.65357
အညီ	-8.65531
ပျောက်	-8.65849
0	-8.66158
R	-8.66158
လိမ်	-8.66226
ဒေါ်လာ	-8.66239
ခွန်	-8.6647
ကျော်	-8.66541
ပိုး	-8.67219
ဒီမိုကရ	-8.67509
ပျော်	-8.67514
မော်လမြိုင်	-8.68879
၁၁	-8.68994

၁၅ -8.69001
 တိုင်းရင်း -8.69097
 ရောဂါ -8.70269
 သဘာဝ -8.70273
 ter -8.70853
 E -8.71676
 အနည်းငယ် -8.7168
 နောင် -8.72327
 ျင်းပ -8.73061
 ခင်ဗျာ -8.73105
 အဆောက်အ -8.73105
 ဆဲလ် -8.73105
 သုတ -8.74066
 လွင် -8.7416
 စာအုပ် -8.74673
 စည် -8.75119
 လျှပ်စစ် -8.76025
 နိမ့် -8.76028
 ကီလို -8.76036
 မော် -8.76166
 အသင်း -8.76198
 ကော် -8.76276
 ဦးသန့် -8.77518
 ကျောင်း -8.77754
 လွှာ -8.79032
 လွယ် -8.79137
 ထွင် -8.79379
 ch -8.79988
 သော်လည်း -8.80199
 သဘော -8.80571
 သဘောတူ -8.81055
 သကဲ့ -8.82134
 ဖျား -8.82145
 နွယ် -8.8215
 ၁၆ -8.82237
 ဖွင့် -8.82486
 ဘွဲ့ -8.83722
 စုစု -8.83851
 ၁၉၃ -8.8388
 ဦး -8.84711
 ပရိတ် -8.85335
 အင်အား -8.8535

ဆုံးဖြတ် -8.8536
 ကြိမ် -8.85403
 ဘေး -8.85542
 ပျံ -8.8663
 - -8.86973
 နာမည် -8.86973
 ခရိုင် -8.86977
 ဘောင်မြင် -8.88265
 % -8.8864
 အစ္စလာမ် -8.8864
 နှင့်အတူ -8.88661
 ပွင့် -8.88692
 သက်ရှိ -8.88841
 အိမ် -8.90246
 ဆော့ဖ် -8.90334
 H -8.90335
 အမျိုးအစား -8.90336
 သြဂ -8.90352
 သုံးစွဲ -8.90438
 အရေးပါ -8.90462
 ရွေးချယ် -8.92059
 ုက္ခ -8.92059
 ဝါဒ -8.9206
 ထူထောင် -8.92061
 ကွဲပြား -8.92063
 နိုဝ -8.92126
 စွန်း -8.92148
 ရိုက -8.92556
 သဏ္ဍ -8.93813
 သေးငယ် -8.93816
 ရာဇ် -8.93821
 ခွံ -8.9387
 F -8.95599
 လေယာဉ် -8.95599
 မဂ္ဂဇင်း -8.95599
 နယ်မြေ -8.95599
 စားသောက် -8.95599
 အယူဝါဒ -8.95599
 နိုင်ငံ -8.96124
 အမေရိက -8.97355
 ation -8.97417
 နှိပ် -8.97417

အထွေထွေ	-8.97417
လက်အောက်	-8.97423
ကြိုးပ	-8.97431
ခေတ်	-8.98168
ဆန့်ကျင်	-8.99269
ပုဂ္ဂိုလ်	-8.99269
ဝေါဟာရ	-8.99269
စီမံ	-8.9927
ရွေးကောက်	-8.99271
ကယ်ဆယ်	-8.99273
ခွာ	-8.99298
အဘယ်	-8.99345
နံကန်	-8.99595
ရင်းနှီး	-9.01155
U	-9.01155
တော်လှန်	-9.01155
ဒဿနိက	-9.01156
တန်ဖိုး	-9.01156
ထွန်းကား	-9.01156
ခန့်မှန်း	-9.01157
မိသားစု	-9.01157
ဥပမာ	-9.01157
စိတ်အပ	-9.01165
စိမ်း	-9.01192
ိုတယ်	-9.01356
မြစ်ဝှမ်း	-9.03079
မြို့	-9.04633
ကဏ္ဍ	-9.05039
ခရစ်ယာန်	-9.05039
ပြဿနာ	-9.0504
သိမ်းပ	-9.05816
ယှဉ်	-9.07039
ပိုင်ဆိုင်	-9.0704
တစ်ခါ	-9.07046
ဂရီ	-9.07181
ဩ	-9.09057
W	-9.0908
ဇူ	-9.0908
ကမ်းရိုးတန်း	-9.0908
ဆွေးနွေး	-9.0908
အထူးသဖြင့်	-9.09083
ရေနံ	-9.09086

ကွင်း	-9.09297
အကြိမ်	-9.11164
အဆင့်အတန်း	-9.11164
သတင်းစာ	-9.11164
စက်တင်	-9.11184
ာဝတီ	-9.12221
မုန်တိုင်း	-9.13291
ကြိုးစား	-9.13326
နဂါး	-9.15465
မှတ်တမ်း	-9.15466
တောင်းဆို	-9.15474
စားသုံး	-9.15503
ချဲ့	-9.15529
ီဂျင်	-9.1656
ရောင်ခြည်	-9.17687
"	-9.24667
x	-9.24667
ဋ	-9.34801
z	-9.40282
0	-9.49111
ဈ	-9.69504
၎	-10.4453
၃	-10.4457
v	-10.4458
ဇ	-10.4459
ဤ	-10.446
၉	-10.4461
ာ	-10.4462
။	-10.4463
ာ	-10.4464

1.10 Sub-word Segmentation with Small Model

```
[36]: %pwd
```

```
[36]: '/home/ye/aif2/word-seg/sub-word/small_data'
```

```
[37]: # 2. Load the trained model.
      small_model = spm.SentencePieceProcessor(model_file='small.model')
```

```
[38]: # 3. Encode raw text into subword pieces (strings) or vocabulary IDs (integers).
```



```

text = "စာမေးပွဲမေးခွန်း ပေါက်ကြားမှုတွေ အကြိမ်ကြိမ် ဖြစ်ပွားခဲ့တာအပေါ် ဒေါသထွက်မှုကနေ ပ
    ပေါ်ပေါက်လာတဲ့ လူငယ်တွေဦးဆောင်တဲ့ လှုပ်ရှားမှုဖြစ်တဲ့ ပိုးဟပ်ပါတီ- Cockroach Janta
    Party (CJP) ဟာ နှစ်ပေါင်းများစွာအတွင်း အိန္ဒိယနိုင်ငံမှာ အကြီးမားဆုံး
    ကျောင်းသားလှုပ်ရှားမှုတစ်ခုအဖြစ် လျင်မြန်စွာ ကြီးထွားလာခဲ့ပါတယ်။"
pieces = small_model.encode(text, out_type=str)
ids = small_model.encode(text, out_type=int)

print(f"Pieces: {pieces}")

```

```

Pieces: [' စာ', ' ', 'မ', ' ', 'ေး', ' ', 'ပွဲ', ' ', 'မ', ' ', 'ေး', ' ', 'ခွန်', ' ', 'း', ' ', ' ', 'ပေါက်', ' ', 'ကြား', ' ',
    'မှု', ' ', 'တ', ' ', 'ွေ', ' ', 'အကြိမ်', ' ', 'ကြ', ' ', 'ိ', ' ', 'မ်', ' ', 'ဖြစ်', ' ', 'ပွား', ' ', 'ဲ', ' ', 'ု', ' ', 'တာ', ' ',
    'အ', ' ', 'ပေါ်', ' ', ' ', 'ဒေါ', ' ', 'သ', ' ', 'ထွက်', ' ', 'မှု', ' ', 'က', ' ', 'နေ', ' ', 'ပေါ်', ' ', 'ပေါက်', ' ', '
    လာ', ' ',
    'တဲ့', ' ', 'လူ', ' ', 'ငယ်', ' ', 'တ', ' ', 'ွေ', ' ', 'ဦး', ' ', 'ဆောင်', ' ', 'တဲ့', ' ', ' ', 'လှုပ်ရှား', ' ', 'မှု', ' ',
    'ဖ', ' ', 'ြ', ' ', 'စ်', ' ', 'တဲ့', ' ', ' ', 'ပိုး', ' ', 'ဟ', ' ', 'ပ်', ' ', 'ပါတီ', ' ', ' ', ' ', 'C', ' ', 'o', ' ',
    'c', ' ', 'k', ' ', 'r', ' ', 'o', ' ', 'a', ' ', 'ch', ' ', ' ', 'J', ' ', 'an', ' ', 't', ' ', 'a', ' ', ' ', 'P', ' ', 'ar', ' ', 't', ' ',
    'y', ' ', ' ', '(', ' ', 'C', ' ', 'J', ' ', 'P', ' ', ')', ' ', 'ဟာ', ' ', 'နှစ်', ' ', 'ပေါင်း', ' ', 'များ', ' ', 'စွာ', ' ', 'အ', ' ',
    'တ', ' ', 'ွေ', ' ', 'င်း', ' ', 'အိန္ဒိယ', ' ', 'နိုင်ငံ', ' ', 'မ', ' ', 'ု', ' ', 'ာ', ' ', 'အ', ' ', 'ကြီးမား', ' ', 'ဆုံး', ' ',
    'ကျောင်း', ' ', 'သား', ' ', 'လှုပ်ရှား', ' ', 'မှု', ' ', 'တစ်', ' ', 'ခ', ' ', 'ု', ' ', 'အ', ' ', 'ဖ', ' ', 'ြ', ' ', 'စ်', ' ',
    'လ', ' ', 'ျ', ' ', 'င်', ' ', 'မြ', ' ', 'န်', ' ', 'စွာ', ' ', 'ကြီး', ' ', 'ထ', ' ', 'ွေ', ' ', 'ား', ' ', 'လာ', ' ', 'ဲ', ' ', 'ု', ' ',
    'ပါတီ', ' ', 'တ', ' ', 'ယ်', ' ', '။']

```

```
[39]: print(f"IDs: {ids}")
```

```

IDs: [273, 14, 146, 238, 14, 146, 837, 23, 3, 332, 223, 322, 32, 212, 971,
283, 70, 225, 13, 582, 707, 7, 167, 26, 277, 3, 745, 50, 518, 322, 28, 239, 193,
332, 334, 237, 85, 304, 32, 212, 227, 136, 237, 3, 825, 322, 116, 189, 68, 237,
3, 839, 108, 82, 372, 289, 890, 3, 403, 140, 320, 726, 235, 140, 156, 871, 3, 0,
446, 172, 156, 3, 545, 460, 172, 381, 3, 0, 403, 0, 545, 0, 622, 101, 316, 665,
117, 26, 32, 56, 47, 252, 924, 14, 999, 53, 6, 760, 118, 264, 80, 825, 322, 480,
84, 61, 26, 116, 189, 68, 42, 151, 46, 93, 24, 117, 120, 114, 56, 87, 334, 707,
7, 372, 32, 97, 998]

```

```

[41]: # 4. Decode IDs or pieces back into the original text.
# The reconstruction is completely lossless and reversible!
print(small_model.decode(ids))

```

စာမေးပွဲမေးခွန်း ပေါက်ကြားမှုတွေ အကြိမ်ကြိမ် ဖြစ်ပွားခဲ့တာအပေါ် ဒေါသထွက်မှုကနေ ပေါ်ပေါက်လာတဲ့ လူငယ်တွေဦးဆောင်တဲ့ လှုပ်ရှားမှုဖြစ်တဲ့ ပိုးဟပ်ပါတီ- Cockroach anta Party C P ဟာ နှစ်ပေါင်းများစွာအတွင်း အိန္ဒိယနိုင်ငံမှာ အကြီးမားဆုံး ကျောင်းသားလှုပ်ရှားမှုတစ်ခုအဖြစ် လျင်မြန်စွာ ကြီးထွားလာခဲ့ပါတယ်။

```
[43]: print(small_model.decode(pieces))
```

စာမေးပွဲမေးခွန်း ပေါက်ကြားမှုတွေ အကြိမ်ကြိမ် ဖြစ်ပွားခဲ့တာအပေါ် ဒေါသထွက်မှုကနေ ပေါ်ပေါက်လာတဲ့ လူငယ်တွေဦးဆောင်တဲ့ လှုပ်ရှားမှုဖြစ်တဲ့ ပိုးဟပ်ပါတီ- Cockroach

Janta Party (CJP) ဟာ နှစ်ပေါင်းများစွာအတွင်း အိန္ဒိယနိုင်ငံမှာ အကြီးမားဆုံး
ကျောင်းသားလှုပ်ရှားမှုတစ်ခုအဖြစ် လျင်မြန်စွာ ကြီးထွားလာခဲ့ပါတယ်။

1.11 Vibe Coding with Z.ai

```
[44]: %pwd
```

```
[44]: '/home/ye/aif2/word-seg/sub-word/small_data'
```

```
[45]: %cd ../
```

```
/home/ye/aif2/word-seg/sub-word
```

1.12 Prompt

ဆရာ LLM ကို လေးတဲ့ prompt က အောက်ပါအတိုင်းပါ။

Hey! Read following code in details:

```
import sentencepiece as spm
```

```
# 1. Train a model directly from a raw text file.
```

```
# (No pre-tokenization or language-specific preprocessing required!)
```

```
spm.SentencePieceTrainer.train(
```

```
    input='data/botchan.txt',
```

```
    model_prefix='m',
```

```
    vocab_size=1000
```

```
)
```

```
# 2. Load the trained model.
```

```
sp = spm.SentencePieceProcessor(model_file='m.model')
```

```
# 3. Encode raw text into subword pieces (strings) or vocabulary IDs (integers).
```

```
text = "I saw a girl with a telescope."
```

```
pieces = sp.encode(text, out_type=str)
```

```
ids = sp.encode(text, out_type=int)
```

```
print(f"Pieces: {pieces}")
```

```
# Output: [' I', ' saw', ' a', ' girl', ' with', ' a', ' ', 'te', 'le', 's', 'c', 'o', 'pe', '.']
```

```
print(f"IDs: {ids}")
```

```
# Output: [9, 459, 11, 939, 44, 11, 4, 142, 82, 8, 28, 21, 132, 6]
```

```
# 4. Decode IDs or pieces back into the original text.
```

```
# The reconstruction is completely lossless and reversible!
```

```
print(sp.decode(ids))
```

```
# Output: "I saw a girl with a telescope."
```

```
print(sp.decode(pieces))
```

```
# Output: "I saw a girl with a telescope."
```

```
=====
```

The code is demo code provided by SentencePiece Github.

I wanna you to write a new python code based on the above code.

I need following facilities:

1. parsing training filename through command line argument (e.g. --corpus or -c)
2. parsing model filename through command line argument (e.g. --model or -m)
3. I think, we should consider mode option for user convenience (e.g. train, decode ids, decode pieces)
4. Similarly, adding vocab size comand line argument is better (e.g. --vocab or -v)
5. We also wanna save tokenized sub-word files as output file. And thus, let's consider --output
6. Add --help command line option too.

```
=====
```

Notes: the above facilities are based on my knowledge of SentencePiece usage. If you want to add more facilities, please let me know.

I need the complete python code for ready to run.

အတန်းထဲမှာ လက်တွေ့ vibe coding လုပ်ပြီး ရေးခဲ့တဲ့ Python code က အောက်ပါအတိုင်းပါ။

```
[61]: from IPython.display import Code, display

# Display a Python file with syntax highlighting
display(Code(filename="sp_tool.py", language="python"))

#!/usr/bin/env python3
"""
A versatile CLI wrapper for SentencePiece.
Supports training, encoding (to IDs or pieces), and decoding (from IDs or
pieces).
"""

import argparse
import sys
import os
import sentencepiece as spm

def main():
    parser = argparse.ArgumentParser(
        description="A CLI tool for training and using SentencePiece models.",
        formatter_class=argparse.RawTextHelpFormatter,
        epilog="""Examples:
# Train a model
python sp_tool.py -m my_model -v 2000 -c train.txt --mode train
"""
    )
```

```

# Encode a text file into subword pieces
python sp_tool.py -m my_model -i input.txt -o encoded_pieces.txt --mode_
↳ encode_pieces

# Encode a text file into IDs
python sp_tool.py -m my_model -i input.txt -o encoded_ids.txt --mode encode_ids

# Decode an ID file back to text
python sp_tool.py -m my_model -i encoded_ids.txt -o decoded.txt --mode_
↳ decode_ids
"""
)

# 1. Corpus argument
parser.add_argument(
    '-c', '--corpus',
    type=str,
    help="Path to the raw text corpus file (required for 'train' mode)."
)

# 2. Model argument
parser.add_argument(
    '-m', '--model',
    type=str,
    required=True,
    help="Model prefix/path. (e.g., 'm' will create/load 'm.model')."
)

# 3. Mode argument
parser.add_argument(
    '--mode',
    type=str,
    required=True,
    choices=['train', 'encode_ids', 'encode_pieces', 'decode_ids',
↳ 'decode_pieces'],
    help="Operation mode."
)

# 4. Vocab size argument
parser.add_argument(
    '-v', '--vocab',
    type=int,
    default=1000,
    help="Vocabulary size for training (default: 1000)."
)

```

```

# 5. Output argument
parser.add_argument(
    '-o', '--output',
    type=str,
    help="Path to the output file (required for encode/decode modes)."
)

# Additional necessary feature: Input argument for encode/decode
parser.add_argument(
    '-i', '--input',
    type=str,
    help="Path to the input file to encode/decode (required for encode/
decode modes)."
)

args = parser.parse_args()

# =====
# MODE: TRAIN
# =====
if args.mode == 'train':
    if not args.corpus:
        parser.error("--corpus (-c) is required when using 'train' mode.")

    if not os.path.exists(args.corpus):
        print(f"Error: Corpus file '{args.corpus}' not found.")
        sys.exit(1)

    print(f"Training SentencePiece model...")
    print(f"  Corpus: {args.corpus}")
    print(f"  Prefix: {args.model}")
    print(f"  Vocab Size: {args.vocab}")

    spm.SentencePieceTrainer.train(
        input=args.corpus,
        model_prefix=args.model,
        vocab_size=args.vocab
    )

    print(f"Training complete. Saved as '{args.model}.model' and '{args.
model}.vocab'.")

# =====
# MODES: ENCODE / DECODE
# =====
else:
    if not args.input or not args.output:

```

```

        parser.error("--input (-i) and --output (-o) are required for encode/
decode modes.")

    # SentencePiece requires the '.model' extension to load.
    # If the user typed '-m my_model', we convert it to 'my_model.model'
    model_file = args.model if args.model.endswith('.model') else f"{args.
model}.model"

    if not os.path.exists(model_file):
        print(f"Error: Model file '{model_file}' not found. Did you train it_
first?")
        sys.exit(1)

    # Load the model
    sp = spm.SentencePieceProcessor(model_file=model_file)

    print(f"Processing '{args.input}' -> '{args.output}' using mode '{args.
mode}'...")

    with open(args.input, 'r', encoding='utf-8') as fin, \
        open(args.output, 'w', encoding='utf-8') as fout:

        for line in fin:
            line = line.strip()
            if not line:
                fout.write('\n')
                continue

            # --- ENCODING ---
            if args.mode == 'encode_ids':
                # Encode to integer IDs
                ids = sp.encode(line, out_type=int)
                # Write as space-separated integers
                fout.write(' '.join(map(str, ids)) + '\n')

            elif args.mode == 'encode_pieces':
                # Encode to string subwords
                pieces = sp.encode(line, out_type=str)
                # Write as space-separated strings
                fout.write(' '.join(pieces) + '\n')

            # --- DECODING ---
            elif args.mode == 'decode_ids':
                # Expecting space-separated integers in the input file
                ids = list(map(int, line.split()))
                decoded_text = sp.decode(ids)
                fout.write(decoded_text + '\n')

```

```

        elif args.mode == 'decode_pieces':
            # Expecting space-separated pieces in the input file
            pieces = line.split()
            decoded_text = sp.decode(pieces)
            fout.write(decoded_text + '\n')

    print("Processing complete!")

if __name__ == '__main__':
    main()

```

[47]: `!python ./sp_tool.py --help`

```

usage: sp_tool.py [-h] [-c CORPUS] -m MODEL --mode
                  {train,encode_ids,encode_pieces,decode_ids,decode_pieces}
                  [-v VOCAB] [-o OUTPUT] [-i INPUT]

```

A CLI tool for training and using SentencePiece models.

options:

```

-h, --help            show this help message and exit
-c CORPUS, --corpus CORPUS
                        Path to the raw text corpus file (required for 'train'
mode).
-m MODEL, --model MODEL
                        Model prefix/path. (e.g., 'm' will create/load
'm.model').
--mode {train,encode_ids,encode_pieces,decode_ids,decode_pieces}
                        Operation mode.
-v VOCAB, --vocab VOCAB
                        Vocabulary size for training (default: 1000).
-o OUTPUT, --output OUTPUT
                        Path to the output file (required for encode/decode
modes).
-i INPUT, --input INPUT
                        Path to the input file to encode/decode (required for
encode/decode modes).

```

Examples:

```

# Train a model
python sp_tool.py -m my_model -v 2000 -c train.txt --mode train

# Encode a text file into subword pieces
python sp_tool.py -m my_model -i input.txt -o encoded_pieces.txt --mode
encode_pieces

# Encode a text file into IDs

```

```
python sp_tool.py -m my_model -i input.txt -o encoded_ids.txt --mode
encode_ids
```

```
# Decode an ID file back to text
python sp_tool.py -m my_model -i encoded_ids.txt -o decoded.txt --mode
decode_ids
```

1.13 SentencePiece Model Building with Big Data

```
[49]: !time python ./sp_tool.py --corpus ./big_data/big_corpus.txt --vocab 1000
      ↪--model ./big_data/big --mode train
```

Training SentencePiece model...

Corpus: ./big_data/big_corpus.txt

Prefix: ./big_data/big

Vocab Size: 1000

sentencepiece_trainer.cc(78) LOG(INFO) Starts training with :

```
trainer_spec {
  input: ./big_data/big_corpus.txt
  input_format:
  model_prefix: ./big_data/big
  model_type: UNIGRAM
  vocab_size: 1000
  self_test_sample_size: 0
  character_coverage: 0.9995
  input_sentence_size: 0
  shuffle_input_sentence: 1
  seed_sentencepiece_size: 1000000
  shrinking_factor: 0.75
  max_sentence_length: 4192
  num_threads: 16
  num_sub_iterations: 2
  max_sentencepiece_length: 16
  split_by_unicode_script: 1
  split_by_number: 1
  split_by_whitespace: 1
  split_digits: 0
  pretokenization_delimiter:
  treat_whitespace_as_suffix: 0
  allow_whitespace_only_pieces: 0
  required_chars:
  byte_fallback: 0
  vocabulary_output_piece_score: 1
  train_extremely_large_corpus: 0
  seed_sentencepieces_file:
  hard_vocab_limit: 1
  use_all_vocab: 0
  unk_id: 0
}
```



```

bos_id: 1
eos_id: 2
pad_id: -1
unk_piece: <unk>
bos_piece: <s>
eos_piece: </s>
pad_piece: <pad>
unk_surface:
enable_differential_privacy: 0
differential_privacy_noise_level: 0
differential_privacy_clipping_threshold: 0
}
normalizer_spec {
  name: nmt_nfkc
  add_dummy_prefix: 1
  remove_extra_whitespaces: 1
  escape_whitespaces: 1
  normalization_rule_tsv:
}
denormalizer_spec {}
trainer_interface.cc(353) LOG(INFO) SentenceIterator is not specified. Using
MultiFileSentenceIterator.
trainer_interface.cc(185) LOG(INFO) Loading corpus: ./big_data/big_corpus.txt
trainer_interface.cc(380) LOG(WARNING) Found too long line (7208 > 4192).
trainer_interface.cc(382) LOG(WARNING) Too long lines are skipped in the
training.
trainer_interface.cc(383) LOG(WARNING) The maximum length can be changed with
--max_sentence_length=<size> flag.
trainer_interface.cc(409) LOG(INFO) Loaded all 43195 sentences
trainer_interface.cc(416) LOG(INFO) Skipped 1 too long sentences.
trainer_interface.cc(425) LOG(INFO) Adding meta_piece: <unk>
trainer_interface.cc(425) LOG(INFO) Adding meta_piece: <s>
trainer_interface.cc(425) LOG(INFO) Adding meta_piece: </s>
trainer_interface.cc(430) LOG(INFO) Normalizing sentences...
trainer_interface.cc(539) LOG(INFO) all chars count=2893308
trainer_interface.cc(550) LOG(INFO) Done: 99.9504% characters are covered.
trainer_interface.cc(560) LOG(INFO) Alphabet size=116
trainer_interface.cc(561) LOG(INFO) Final character coverage=0.999504
trainer_interface.cc(592) LOG(INFO) Done! preprocessed 43195 sentences.
unigram_model_trainer.cc(265) LOG(INFO) Making suffix array...
unigram_model_trainer.cc(269) LOG(INFO) Extracting frequent sub strings...
node_num=1464589
unigram_model_trainer.cc(312) LOG(INFO) Initialized 49286 seed sentencepieces
trainer_interface.cc(598) LOG(INFO) Tokenizing input sentences with whitespace:
43195
trainer_interface.cc(609) LOG(INFO) Done! 24586
unigram_model_trainer.cc(602) LOG(INFO) Using 24586 sentences for EM training
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=0 size=18728 obj=9.65149

```

```

num_tokens=52632 num_tokens/piece=2.81034
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=1 size=14614 obj=8.03601
num_tokens=52727 num_tokens/piece=3.60798
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=0 size=10941 obj=8.0102
num_tokens=54950 num_tokens/piece=5.02239
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=1 size=10907 obj=7.98306
num_tokens=54968 num_tokens/piece=5.0397
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=0 size=8178 obj=8.03602
num_tokens=59318 num_tokens/piece=7.25336
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=1 size=8175 obj=8.02295
num_tokens=59321 num_tokens/piece=7.25639
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=0 size=6131 obj=8.11131
num_tokens=64741 num_tokens/piece=10.5596
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=1 size=6128 obj=8.09332
num_tokens=64745 num_tokens/piece=10.5654
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=0 size=4596 obj=8.22564
num_tokens=70654 num_tokens/piece=15.3729
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=1 size=4596 obj=8.19815
num_tokens=70655 num_tokens/piece=15.3732
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=0 size=3447 obj=8.3875
num_tokens=77238 num_tokens/piece=22.4073
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=1 size=3446 obj=8.35378
num_tokens=77239 num_tokens/piece=22.4141
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=0 size=2584 obj=8.6028
num_tokens=83961 num_tokens/piece=32.4926
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=1 size=2584 obj=8.55065
num_tokens=83961 num_tokens/piece=32.4926
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=0 size=1938 obj=8.90224
num_tokens=91750 num_tokens/piece=47.3426
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=1 size=1938 obj=8.83313
num_tokens=91750 num_tokens/piece=47.3426
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=0 size=1453 obj=9.28215
num_tokens=99408 num_tokens/piece=68.4157
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=1 size=1453 obj=9.19197
num_tokens=99408 num_tokens/piece=68.4157
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=0 size=1100 obj=9.66024
num_tokens=108079 num_tokens/piece=98.2536
unigram_model_trainer.cc(618) LOG(INFO) EM sub_iter=1 size=1100 obj=9.5623
num_tokens=108079 num_tokens/piece=98.2536
trainer_interface.cc(687) LOG(INFO) Saving model: ./big_data/big.model
trainer_interface.cc(699) LOG(INFO) Saving vocabs: ./big_data/big.vocab
Training complete. Saved as './big_data/big.model' and './big_data/big.vocab'.

real    0m1.170s
user    0m3.870s
sys     0m0.064s

```

```
[50]: !ls ./big_data/big* -lh
```

```
-rw-rw-r-- 1 ye ye 7.2M Jul 25 18:04 ./big_data/big_corpus.txt
-rw-rw-r-- 1 ye ye 254K Jul 25 18:36 ./big_data/big.model
-rw-rw-r-- 1 ye ye 23K Jul 25 18:36 ./big_data/big.vocab
```

```
[51]: !wc ./big_data/big.vocab
```

```
1000 2000 22638 ./big_data/big.vocab
```

```
[52]: !head -n 100 ./big_data/big.vocab
```

```
<unk> 0
<s> 0
</s> 0
-2.68312
။ -2.9847
အ -4.0697
ကို -4.12678
ပါ -4.17861
သည် -4.21128
က -4.2706
တယ် -4.35374
မ -4.5086
မှာ -4.61696
ရ -4.61753
၊ -4.70651
များ -4.78877
း -4.87653
မ -4.95004
ဲ့ -4.96331
ခ -4.96374
့ -5.01397
ရှိ -5.01679
ဖြစ် -5.12699
တို့ -5.21682
သ -5.22249
နေ -5.22491
တစ် -5.24481
အ -5.30291
င် -5.30373
တာ -5.30822
တွင် -5.32939
ပြီး -5.34236
သော -5.36372
တ -5.36413
က -5.37231
```

န	-5.43892
ကျွန်တော်	-5.47285
သ	-5.47549
သွား	-5.48555
ဒီ	-5.49033
ဘယ်	-5.51376
ဝ	-5.52639
လို့	-5.53147
တွေ	-5.53395
တဲ့	-5.55395
လဲ	-5.55462
ကြ	-5.55827
နဲ့	-5.56313
နှင့်	-5.57517
၏	-5.59047
လ	-5.59317
ခင်ဗျား	-5.5957
လား	-5.60254
ရ	-5.60642
င်း	-5.61317
ပေး	-5.62705
ေ	-5.66901
သူ	-5.69044
မှ	-5.69276
နိုင်	-5.70451
ို	-5.70589
ဘူး	-5.71747
မ်း	-5.73264
မယ်	-5.74114
စ်	-5.78229
ာ	-5.79695
လာ	-5.80343
တ်	-5.86419
ော	-5.9101
န	-5.91945
မြ	-5.92203
်	-5.94182
က်	-5.94299
ခ	-5.97681
ဲ	-5.98376
ွ	-5.98774
တော့	-6.00247
ထား	-6.00658
ိ	-6.02021

ယ်	-6.02397
ဝ	-6.03388
နိုင်ငံ	-6.06131
ဆို	-6.06459
စ	-6.07263
ကျ	-6.08114
လ	-6.08567
လည်း	-6.09348
စ	-6.09599
၍	-6.1014
ောက်	-6.11338
မှု	-6.1163
ရင်	-6.13037
ထ	-6.13153
ပ်	-6.13161
ချင်	-6.13835
ဲ	-6.1484
လူ	-6.15512
တ	-6.16744
ရေး	-6.16944
လုပ်	-6.1868

1.14 Sub-Word Segmentation with Big SentencePiece Model

We prepared test data copied from BBC Burmese news.

```
[53]: !cat ./big_data/bbc-cockroach-news.txt
```

ဆူတစ် ဘစ္စဝါး
 ရာထူးတာဝန်, အိန္ဒိယသတင်းထောက်
 ရေးသားခဲ့သည်။
 လွန်ခဲ့သော ၁၂ မိနစ် က
 ဖတ်ရန်အချိန်: မိနစ် ၈
 ကိုယ့်အနာဂတ်ကို ဆုံးဖြတ်ပေးမယ့် စာမေးပွဲတွေကို ယုံကြည်လို့မရတော့ဘူးဆိုရင် ဘာကို
 ယုံကြည်ရမလဲဆိုတဲ့ စိုးရိမ်ကြောက်ရွံ့မှုကနေ ဒီလူပျိုရှားမှု စတင်ခဲ့တာပါ။
 အဲဒီခံစားချက်ဟာ အိန္ဒိယနိုင်ငံက လူငယ်သန်းပေါင်းများစွာနဲ့ ရင်းနှီးပြီးသား
 ဖြစ်ပါတယ်။

ရက်သတ္တပတ်အနည်းငယ်အကြာ ဇူလိုင် ၂၀ ရက်မှာတော့ လူငယ်အမျိုးသား၊ အမျိုးသမီး
 သောင်းနဲ့ချီက အိန္ဒိယလွှတ်တော်ဆီ ချီတက်ဖို့ ကြိုးပမ်းခဲ့ကြပါတယ်။ ရဲတပ်ဖွဲ့ကတော့
 မျက်ရည်ယိုဗုံးသုံးပြီး တုတ်နဲ့ရိုက်နှက်ဖြိုခွင်းမှုတွေ လုပ်ခဲ့ပါတယ်။
 အဲဒီနောက်ပိုင်း ရက်တွေမှာလည်း နောက်ထပ်ထောင်ပေါင်းများစွာသော လူငယ်တွေဟာ
 လမ်းပေါ်ကို ထပ်ပြီးထွက်လာခဲ့ကြပါတယ်။

စာမေးပွဲမေးခွန်း ပေါက်ကြားမှုတွေ အကြိမ်ကြိမ် ဖြစ်ပွားခဲ့တာအပေါ် ဒေါသထွက်မှုကနေ ပေါ်ပေါက်လာတဲ့ လူငယ်တွေဦးဆောင်တဲ့ လှုပ်ရှားမှုဖြစ်တဲ့ ပိုးဟပ်ပါတီ- Cockroach Janta Party (CJP) ဟာ နှစ်ပေါင်းများစွာအတွင်း အိန္ဒိယနိုင်ငံမှာ အကြီးမားဆုံး ကျောင်းသားလှုပ်ရှားမှုတစ်ခုအဖြစ် လျင်မြန်စွာ ကြီးထွားလာခဲ့ပါတယ်။

CJP လှုပ်ရှားမှုက ပညာရေးစနစ် ပြုပြင်ပြောင်းလဲရေးနဲ့ အိန္ဒိယပညာရေးဝန်ကြီး ဩမန်ဒရာ ပရာဒန် ရာထူးက နုတ်ထွက်ပေးဖို့ တောင်းဆိုနေပါတယ်။

ဒီလှုပ်ရှားမှုရဲ့ အဓိကပုဂ္ဂိုလ်တစ်ဦးကတော့ တက်ကြွလှုပ်ရှားသူ ဆိုနမ် ဝမ်ချွတ် ဖြစ်ပါတယ်။ သူက ဒီလှုပ်ရှားမှုကို ထောက်ခံတဲ့ ၂၆ ရက်ကြာ အစာငတ်ခံဆန္ဒပြမှုအတွင်း ကိုယ်အလေးချိန် ၁၁ ကီလိုဂရမ် (၂၄ ပေါင်) ကျသွားခဲ့တယ်လို့ ပြောပါတယ်။

ဆိုနမ် ဝမ်ချွတ် ဟာ ဇူလိုင် ၂၃ ကြာသပတေးနေ့နောင်းပိုင်းမှာ အစာငတ်ခံဆန္ဒပြမှုကို ရပ်နားခဲ့ပေမယ့် ကျောင်းသားခေါင်းဆောင်တွေကတော့ သူတို့ရဲ့ တောင်းဆိုချက်တွေ မရမချင်း ဆန္ဒပြမှုတွေ ဆက်လုပ်သွားမယ်လို့ ပြောထားပါတယ်။

အခု အဓိကမေးခွန်းကတော့ ဒီဖြစ်ရပ်ဟာ သာမန်ကျောင်းသားဆန္ဒပြပွဲတစ်ခုပဲလား၊ ဒါမှမဟုတ် ပိုကြီးမားတဲ့ နိုင်ငံရေးလှုပ်ရှားမှုတစ်ခုရဲ့ အစလားဆိုတာ ဖြစ်ပါတယ်။ သမိုင်းကြောင်းကတော့ ဒီအပေါ်မှာ သတိထားဖို့ရော မျှော်လင့်ချက်ရှိစရာပါ နှစ်မျိုးလုံးအတွက် အကြောင်းပြချက်တွေရှိနေပါတယ်။

အိန္ဒိယနိုင်ငံရေးကို ပြောင်းလဲစေခဲ့တဲ့ ကျောင်းသားလှုပ်ရှားမှုတွေဟာ အတိတ်မှာ အကြိမ်ကြိမ် ပေါ်ပေါက်ခဲ့ပါတယ်။ ၁၉၇၀ ပြည့်လွန်နှစ်တွေအတွင်း စီးပွားရေး အကျပ်အတည်းနဲ့ အကျင့်ပျက်ချစားမှုတွေကို ကျောင်းသားတွေနဲ့ လူလတ်တန်းစားတွေ ဦးဆောင်ပြီး ဆန့်ကျင်ခဲ့တဲ့ ဂူဂျာရတ်ပြည်နယ်က Nav Nirman လှုပ်ရှားမှုဟာ ဝါရင့်ဆိုရှယ်လစ်ခေါင်းဆောင် ဂျာယာပရာကတ်ရှ် နာရာယန် က ဝန်ကြီးချုပ်အင်ဒီရာဂန္တီ ကို ဆန့်ကျင်တဲ့ နိုင်ငံရေးလှုပ်ရှားမှု ပေါ်ပေါက်လာစေတဲ့ အကြောင်းရင်းတစ်ခု ဖြစ်ခဲ့ပါတယ်။

```
[57]: !python ./sp_tool.py --mode encode_pieces --model ./big_data/big --input ./
      ↪big_data/bbc-cockroach-news.txt --output ./big_data/bbc-cockroach-news.sp
```

```
Processing './big_data/bbc-cockroach-news.txt' -> './big_data/bbc-cockroach-
news.sp' using mode 'encode_pieces'...
Processing complete!
```

```
[58]: !cat ./big_data/bbc-cockroach-news.sp
```

```
ဆ ဣ တ ဖ် ဘ စွ ဝါ ို ဖ်
ရာ ထ ဣ တာ ဝန် , အ ိ န ို ဒ ိ ယ သ တင်း ထောက်
ရေး သား ခ ို သည် ။
လ ိုန် ခ ို သော ၁၂ မိ နှစ် က
ဖ တ် ရ န် အ ချိန် : မိ နှစ် ၈
```

ကိုယ် ၊ အ နာ ဂ တ် က ခို ဆုံးဖြတ် ပေး မ ယ့် စာမေးပွဲ တ ဝှေ့ က ခို ယုံကြည် လို ▢
↪ ဝှေ့ မ
ရ တော့ ဘ ဉ္စး ဆို ရ င် ဘာ က ခို ယုံကြည် ရ မလဲ ဆို တဲ့ စိုး ရိ မ် ကြ ဆောက် ရ ▢
↪ ဝှေ့ ဝှေ့
မူ က နေ ဒီ လ ို ဝှေ့ ရှား မူ စတင် ခ ဝှေ့ တာ ပါ ။ အဲဒီ ခံ စား ချက် ဟ ဘာ အိန္ဒိယ
န ခိုင် င ဝံ က လူ ငယ် သ န်း ပေါင်း များ စွာ န ဝှေ့ ရ င်း န ို ဝှေ့ ပြီး သား ဖြစ် ပါ
တယ် ။

ရက် သတ္တ ပတ် အ နည်း ငယ် အ ကြာ ဇ ို လို င် ၂၀ ရက် မ ို ဘာ တော့ လူ ▢
↪ ငယ် အ မျိုး
သား ၊ အမျိုးသမီး သော င်း န ဝှေ့ ချီ က အိန္ဒိယ လွတ် တော် ဆီ ချီ တ က် ဖို ို
ကြို ိုး ပ မ်း ခ ဝှေ့ ကြ ပါ တယ် ။ ရ ဝဲ တ ပ် ဖွဲ့ က တော့ မျက် ရည် ယ ခို ဗ ဝံ ▢
↪ ိုး သုံး
ပြီး တ ဝှေ့ န ဝှေ့ ရိုက် န ို က် ဗ ို ခ ဝှေ့ င်း မူ တ ဝှေ့ လုပ် ခ ဝှေ့ ပါ တယ် ။ ▢
↪ အဲဒီ
နောက် ပိုင်း ရက် တ ဝှေ့ မ ို ဘာ လည် ိုး နောက် ထပ် ထောင် ပေါင်း များ စွာ သော ▢
↪ လူ ငယ်
တ ဝှေ့ ဟ ဘာ လမ်း ပေါ် က ခို ထပ် ပြီး ထွက် လာ ခ ဝှေ့ ကြ ပါ တယ် ။

စာမေးပွဲ မ ိုး ခ ဝှေ့နီး ပေါက် ကြား မူ တ ဝှေ့ အ ကြ ို မ် ကြ ို မ် ဖြစ် ပွား ခ ဝှေ့
တာ အ ပေါ် ဒေါ သ ထွက် မူ က နေ ပေါ် ပေါက် လာ တဲ့ လူ ငယ် တ ဝှေ့ ဦး ▢
↪ ဆောင် တဲ့
လှုပ်ရှား မူ ဖြစ် တဲ့ ပိုး ဟ ပ် ပါ တီ - Cockroach Janta Party (CJP) ဟာ နှစ် ပေါင်း များ စွာ အ တွင်း အိန္ဒိယ န ခိုင် င ဝံ မ ို ဘာ
အ ကြီးမား ဆုံး ကျောင်းသား လ ို ဝှေ့ ရှား မူ တ စ် ခ ို အ ဖြစ် လျင် မြ န် စွာ
ကြီး ထ ဝှေ့ ဘား လာ ခ ဝှေ့ ပါ တယ် ။

CJP လှုပ်ရှား မူ က ပညာ ရေး စ နှစ် ပြု ပြင် ပြော င်း လဲ ရေး န ဝှေ့ အိန္ဒိယ
ပညာ ရေး ဝန် ကြီး ဒ ို ဘာ မ န် ဒ ရာ ပ ရာ ဒ န် ရာ ထ ဉ္စး က န ို တ် ထွက် ▢
↪ ပေး ဖို ို
တောင် ိုး ဆို နေ ပါ တယ် ။

ဒီ လ ို ဝှေ့ ရှား မူ ရ ဝှေ့ အဓိက ပု ဂ ို ဂ ခို လ် တ စ် ဦး က တော့ တက် ကြ ▢
↪ လ ို ဝှေ့
ရှား သူ ဆို န မ် ဝ မ် ချ ို တ် ဖြစ် ပါ တယ် ။ သူ က ဒီ လ ို ဝှေ့ ရှား မူ က ခို
ထောက် ခံ တဲ့ ၂ ဖ ရက် ကြာ အ စာ င တ် ခံ ဆ န ို ဒ ပြ မူ အ တွင်း ကိုယ် အ ▢
↪ လေး
ချိန် ၁၁ ကီလို ဂ ရ မ် (၂၄ ပေါ င်) ကျ သွား ခ ဝှေ့ တယ် လို ို ပြော ပါ တယ်
။

ဆို န မ် ဝ မ် ချ ို တ် ဟာ ဇ ို လို င် ၂၃ ကြာ သ ပ တ ိုး နေ န ို တေ င်း
ပိုင်း မ ို ဘာ အ စာ င တ် ခံ ဆ န ို ဒ ပြ မူ က ခို ရပ် နား ခ ဝှေ့ ပ ို မ ယ့်

ကျောင်းသား ခေါင်းဆောင် တ ဝှောင် က တော့ သူ တို့ ဝှောင် ရဲ့ တောင် ဝှောင် ဆို ချက် တ ဝှောင်
 မ ချင်း ဆ န ဝှောင် ပြ မှု တ ဝှောင် ဆက် လ ဝှောင် သွား မ ယ် လို ဝှောင် ပြော ထား ပါ
 တယ် ။

အခု အဓိက မ ဝှောင် ဝှောင် က တော့ ဒီ ဖြစ် ရပ် ဟ ဝှောင် သာ မ န် ကျောင်း သား ဆ
 န ဝှောင် ပြ
 ပွဲ တ စ် ခ ဝှောင် ပ ဝှောင် လား ၊ ဒါမှမဟုတ် ပို ကြီးမား တဲ့ နိုင်ငံ ရေး လ ဝှောင် ဝှောင် ရှား
 မှု တ စ် ခ ဝှောင် ရ ဝှောင် အ စ လား ဆို တာ ဖြစ် ပါ တယ် ။ သမိုင်း ကြောင်း က တော့ ဒီ
 အ
 ပေါ် မ ဝှောင် ဝှောင် သ တိ ထား ပို ဝှောင် ရ တော့ မှု ဆောင် လ ဝှောင် ချက် ရှိ စရာ ပါ နှစ် မျိုး
 လုံး အ တ ဝှောင် အကြောင်း ပြ ချက် တ ဝှောင် ရှိ နေ ပါ တယ် ။

အိန္ဒိယ န ဝှောင် ဝှောင် ရေး က ဝှောင် ပြောင်းလဲ စ ဝှောင် ခ ဝှောင် တဲ့ ကျောင်းသား လ ဝှောင် ဝှောင် ရှား
 မှု တ ဝှောင် ဟ ဝှောင် အ တ ဝှောင် မ ဝှောင် အ ကြ ဝှောင် ဝှောင် ပေါ် ပေါက် ခ ဝှောင် ပါ
 တယ် ။ ၁၉ ၇ ၀
 ပြ ည့် လ ဝှောင် နှစ် တ ဝှောင် အ တွင်း စီးပွား ရေး အ ကျ ဝှောင် အ တည်း န ဝှောင် အ ကျ ဝှောင်
 ပျက်
 ချ စား မှု တ ဝှောင် က ဝှောင် ကျောင်းသား တ ဝှောင် န ဝှောင် လူ လ တ် တန်း စား တ ဝှောင်
 ဦး ဆောင် ပြီး
 ဆ န ဝှောင် ကျ ဝှောင် ခ ဝှောင် တဲ့ ဝှောင် ဝှောင် ဝှောင် ပြ ည့် နယ် က Nav Nirman
 လှုပ်ရှား မှု ဟ ဝှောင် ဝှောင် ရ ဝှောင် ဆို ရ ဝှောင် ယ် လ စ် ခေါင်းဆောင် ဝှောင် ဝှောင် ဝှောင် က
 တ် ရ
 ဝှောင် နာ ရာ ယ န် က ဝှောင်ကြီး ချုပ် အ ဝှောင် ဒီ ရာ ဝှောင် န ဝှောင် ဒီ ကို ဆ န် ကျ ဝှောင် တဲ့
 နိုင်ငံ ရေး လ ဝှောင် ဝှောင် ရှား မှု ပေါ် ပေါက် လာ စ ဝှောင် တဲ့ အကြောင်း ရင်း တ စ် ခ ဝှောင်
 ဖြစ် ခ ဝှောင် ပါ တယ် ။

```
[59]: !python ./sp_tool.py --mode encode_ids --model ./big_data/big --input ./
      big_data/bbc-cockroach-news.txt --output ./big_data/bbc-cockroach-news.id
```

```
Processing './big_data/bbc-cockroach-news.txt' -> './big_data/bbc-cockroach-
news.id' using mode 'encode_ids'...
Processing complete!
```

```
[60]: !cat ./big_data/bbc-cockroach-news.id
```

```
153 121 33 64 224 748 245 20 64
283 92 157 226 380 836 27 78 69 997 142 78 135 37 353 545
98 123 73 18 478 991
85 140 73 18 470 792 253 369 9
163 67 53 35 27 298 0 253 369 3 231
315 20 27 204 168 67 34 60 888 418 17 829 983 33 570 34 60 891 100 20 17 53 874
222 157 235 53 28 112 34 60 891 53 227 235 44 3 753 334 251 266 89 53 75 447 302
34 316 39 50 998 160 771 302 629 73 18 226 383 991 218 257 156 347 171 65 503 69
114 278 129 34 96 375 37 104 483 519 202 69 18 13 54 69 998 177 723 123 22 383
```


645 991

242 37 280 535 27 559 375 27 493 3 189 121 100 28 826 242 17 998 65 874 96 375
27 894 123 999 946 32 54 69 18 796 34 503 802 137 584 3 796 33 72 607 20 3 619
16 80 62 73 18 266 383 645 991 13 95 33 93 875 34 874 3 627 367 135 60 416 172
16 441 723 97 225 69 18 574 69 998 72 173 197 60 73 75 54 302 33 570 99 73 18
383 645 991 218 616 451 242 33 570 17 998 65 394 16 187 572 312 483 519 202 470
96 375 33 570 171 65 276 372 34 60 517 723 567 281 73 18 266 383 645 991

983 17 116 73 237 3 341 249 302 33 570 5 266 78 251 266 78 251 22 746 73 18 226
27 372 3 682 37 567 302 34 316 199 341 281 44 96 375 33 570 995 16 196 44 967
302 939 44 3 844 171 93 383 325 918 3 556 213 294 754 358 213 178 294 306 3 0
537 206 178 3 686 636 206 554 3 0 556 0 686 0 148 113 483 519 202 27 643 503 69
114 278 129 17 998 65 5 914 132 573 50 998 160 771 302 33 64 73 108 27 939 3 922
70 35 202 174 92 75 150 281 73 18 383 645 991

3 556 0 686 967 302 34 282 183 87 369 3 194 221 495 54 149 183 69 18 503 823 183
380 105 3 142 197 65 17 35 142 102 155 102 142 35 283 92 157 34 139 225 567 418
607 20 184 16 235 316 383 645 991

39 50 998 160 771 302 53 18 699 505 168 997 168 60 396 33 64 995 16 34 874 485
734 50 998 160 771 499 82 69 251 3 41 251 136 452 22 383 645 991 57 34 39 50 998
160 771 302 34 60 3 545 257 44 268 264 242 493 5 131 278 67 257 103 69 997 142
158 302 27 643 315 27 273 298 205 320 921 168 53 251 3 0 371 468 3 701 28 0 120
620 73 18 645 100 20 110 383 645 991

82 69 251 3 41 251 136 452 148 3 189 121 100 28 268 356 287 37 80 33 116 297 69
998 68 54 451 17 998 65 5 131 278 67 257 103 69 997 142 158 302 34 60 534 445 73
18 80 56 17 829 573 531 196 33 570 34 874 57 303 20 53 18 184 16 235 347 33 570
11 53 17 201 153 69 997 142 158 302 33 570 388 50 160 620 17 79 100 20 110 333
383 645 991

295 699 17 116 73 237 34 874 39 939 293 171 65 229 17 35 905 123 103 69 997 142
158 223 33 64 73 108 80 95 175 999 907 171 225 255 914 44 81 183 50 998 160 771
302 33 64 73 108 53 18 5 87 175 235 226 22 383 645 991 872 323 34 874 39 27 372
17 998 65 24 239 333 607 20 53 68 3 349 68 71 50 252 347 147 389 383 113 894 292
27 33 413 450 158 347 33 570 147 316 383 645 991

503 69 114 278 129 183 34 60 710 87 56 73 18 44 573 50 998 160 771 302 33 570
171 65 5 33 144 17 998 65 5 266 78 251 266 78 251 199 341 73 18 383 645 991 331
230 141 143 419 50 140 621 33 570 27 643 640 183 5 84 93 27 430 69 18 5 84 115
575 136 156 302 33 570 34 60 573 33 570 69 18 96 50 67 256 156 33 570 126 196
723 153 35 20 84 28 73 18 44 363 121 262 65 53 67 158 307 324 34 3 839 178 853 3
839 170 358 327 537 967 302 171 65 3 245 53 252 235 53 998 79 50 64 531 196 3
262 65 209 80 102 34 67 53 998 71 3 204 102 135 35 9 868 397 27 28 560 102 168
69 997 560 6 153 684 84 28 44 81 183 50 998 160 771 302 199 341 281 87 56 44 450
439 33 64 73 108 22 73 18 383 645 991

[]: